


UNIVERSIDADE POLITÉCNICA DE SANTARÉM
Escola Superior de Gestão e Tecnologia de Santarém



**Geração de Dados Sintéticos para Gestão Energética de
Edifícios: Uma Abordagem Estatístico-Temporal para Data
Augmentation**

Dissertação

Mestrado em Informática Aplicada

Tiago José Pina da Silva Esteves

Orientação:

Prof.º Pedro Miguel de Oliveira Martins

Prof.ª Maryam Abbasi

setembro, 2026

Esta cópia da tese é fornecida na condição de que quem a consulta reconhece que os direitos de autor são pertença do autor da tese e que nenhuma citação ou informação obtida a partir dela pode ser publicada sem a referência apropriada.

This copy of the thesis has been supplied on condition that anyone who consults it is understood to recognize that its copyright rests with its author and that no quotation from the thesis and no information derived from it may be published without proper acknowledgement.

Agradecimentos

A conclusão desta etapa não teria sido possível sem a colaboração e o apoio de várias pessoas, às quais deixo o meu agradecimento.

Em primeiro lugar, agradeço à Escola Superior de Gestão e Tecnologia de Santarém (ESGTS) e a todos os docentes do Curso de Mestrado em Informática Aplicada (MIA) pelo acompanhamento e pelos conhecimentos transmitidos.

Ao professor Filipe Madeira, coordenador do curso, agradeço a disponibilidade e a ajuda prestadas durante o mestrado.

Ao professor Pedro Martins, meu orientador, agradeço o apoio e a orientação constantes durante a elaboração desta dissertação.

À professora Maryam Abbasi, minha coorientadora, agradeço igualmente o contributo dado a este trabalho.

À minha família, agradeço todo o apoio e incentivo que me permitiram chegar até esta etapa e concluir o mestrado.

À minha mulher, um agradecimento especial pelo apoio, pela compreensão e pelos conselhos ao longo das diferentes fases da dissertação.

A todos, um muito obrigado.

Siglas e Acrónimos

ACF *Autocorrelation Function*

AR(1) processo autorregressivo de primeira ordem

BDG2 *Building Data Genome Project 2*

CV coeficiente de variação

F1-score F-measure

GAN *Generative Adversarial Network*

GRU *Gated Recurrent Unit*

KS Kolmogorov–Smirnov

LSTM *Long Short-Term Memory*

MAE *Mean Absolute Error*

MAPE *Mean Absolute Percentage Error*

NRMSE *Normalized Root Mean Square Error*

RMSE *Root Mean Square Error*

Resumo

Esta dissertação avalia o efeito de dados sintéticos no treino de modelos de previsão do consumo energético e de deteção de anomalias com pouco histórico real. O estudo usou edifícios de educação do Building Data Genome Project 2 (BDG2) e um gerador estatístico-temporal estimado nos edifícios de calibração, distintos dos de avaliação. Na previsão, com Prophet, compararam-se cenários com 5%, 10% e 20% de histórico real, com reforço sintético e com um cenário de controlo com ruído branco. Na deteção, usou-se o Isolation Forest, com anomalias artificiais introduzidas no período de teste. Na previsão, os dados sintéticos reduziram o erro face ao treino escasso, sem vantagem demonstrada face ao ruído branco. Na deteção, o reforço sintético reduziu o F1-score, pela queda do *recall*. O efeito dos dados sintéticos depende, assim, da tarefa: na previsão, o ganho é compatível com a reposição da janela de treino com mais observações.

Palavras-chave

dados sintéticos; gestão energética de edifícios; previsão de consumo; deteção de anomalias; *data augmentation*; Prophet; Isolation Forest.

Abstract

Synthetic Data Generation for Building Energy Management: A Statistical-Temporal Approach to Data Augmentation

This dissertation evaluates the effect of synthetic data in the training of energy consumption forecasting and anomaly detection models with little real history. The study used education buildings from the Building Data Genome Project 2 (BDG2) and a statistical-temporal generator estimated on the calibration buildings, which were distinct from the evaluation buildings. For forecasting, with Prophet, scenarios with 5%, 10% and 20% of real history were compared, with synthetic reinforcement and with a white noise control scenario. For detection, Isolation Forest was used, with artificial anomalies introduced in the test period. In forecasting, the synthetic data reduced the error compared with scarce training, with no advantage demonstrated over white noise. In detection, synthetic reinforcement reduced the F1-score, through the drop in recall. The effect of synthetic data therefore depends on the task: in forecasting, the gain is consistent with restoring the training window with additional observations.

Keywords

synthetic data; building energy management; consumption forecasting; anomaly detection; data augmentation; Prophet; Isolation Forest.

Conteúdo

Siglas e Acrónimos	ii
Lista de Figuras	x
Lista de Tabelas	xi
1 Introdução	1
1.1 Enquadramento	1
1.2 Problema de Investigação	2
1.3 Questão de Investigação	3
1.4 Objetivos	3
1.5 Contributos do trabalho	4
1.6 Estrutura da dissertação	4
2 Estado da Arte	6
2.1 Gestão energética e séries de consumo em edifícios	6
2.2 Previsão do consumo energético	7
2.3 Escassez de dados em séries temporais	8
2.4 Dados sintéticos e <i>data augmentation</i>	9
2.5 Detecção de anomalias no consumo energético	12
2.6 Posicionamento dos modelos usados	13
2.7 Síntese da literatura revista	14
3 Metodologia	18
3.1 Enquadramento metodológico	18

3.2	<i>Dataset</i> utilizado	19
3.3	Seleção dos edifícios	20
3.4	Preparação do <i>dataset</i> de modelação	21
3.5	Análise exploratória inicial	22
3.6	Geração de dados sintéticos	25
3.6.1	Princípio geral do gerador	25
3.6.2	Divisão temporal das séries	26
3.6.3	Perfil horário e semanal	27
3.6.4	Efeito térmico	27
3.6.5	Componente residual e processo AR(1)	28
3.6.6	Aplicação aos edifícios <i>held-out</i>	28
3.7	Validação dos dados sintéticos	29
3.8	Desenho experimental	30
3.8.1	Objetivo da avaliação	30
3.8.2	Cenários experimentais	31
3.8.3	Coerência temporal dos cenários de escassez	32
3.9	Previsão do consumo	33
3.10	Avaliação da previsão	33
3.11	Deteção de anomalias	34
3.11.1	Modelo utilizado	34
3.11.2	Construção das variáveis	34
3.11.3	Injeção de anomalias artificiais	35
3.11.4	Métricas de avaliação	35
3.12	Múltiplos <i>splits</i> e estabilidade dos resultados	36
3.13	Análise estatística	36
3.14	Ferramentas e bibliotecas utilizadas	38

3.15	Delimitações metodológicas	39
3.16	Síntese da metodologia	40
4	Resultados	41
4.1	Introdução ao capítulo	41
4.2	Validação dos dados sintéticos	41
4.2.1	Comportamento do gerador sintético	41
4.2.2	Distribuições, ritmos semanais e detalhe temporal	43
4.3	Efeito dos dados sintéticos na previsão do consumo	47
4.3.1	Impacto da escassez de dados reais no erro de previsão	47
4.3.2	Consistência dos resultados entre <i>splits</i>	50
4.4	Variação dos resultados entre edifícios	51
4.4.1	Diferenças no efeito dos dados sintéticos por edifício	51
4.4.2	Síntese quantitativa dos ganhos no cenário de 20%	53
4.5	Análise estatística dos resultados da previsão	55
4.5.1	Comparação entre dados reais escassos e dados reais com sintético	55
4.5.2	Comparação entre dados sintéticos e ruído branco	56
4.6	Resultados da deteção de anomalias	58
4.6.1	Comparação entre cenários	58
4.6.2	Interpretação da queda do F1	60
4.7	Discussão dos resultados	61
5	Conclusões	63
5.1	Síntese do trabalho realizado	63
5.2	Resposta à questão de investigação	63
5.3	Principais conclusões	64

5.4	Limitações do estudo	65
5.5	Trabalho futuro	66
5.6	Considerações finais	67
Bibliografia		68
Glossário		72
Apêndices		73
A	<i>Pipeline</i> experimental e scripts	73
A.1	Inventário dos scripts	73
A.2	Sequência de execução	75
A.3	Composição dos <i>splits</i>	75
A.4	Ligações ao corpo	75
B	Gerador e configuração experimental	77
B.1	Pseudocódigo do gerador	77
B.2	Parâmetros do gerador	78
B.3	Configuração do Prophet	78
B.4	Configuração do Isolation Forest	79
B.5	Sementes e injeção de anomalias	79
C	Resultados complementares	80
C.1	Previsão por <i>split</i>	80
C.2	Ganhos por edifício no cenário de 20%	82
C.3	Testes de Wilcoxon por <i>split</i>	83
C.4	Deteção de anomalias por cenário e por <i>split</i>	85
C.5	Execução de verificação	86

C.5.1	Reprodutibilidade	87
C.5.2	Sensibilidade ao <code>changepoint_prior_scale</code>	87
C.5.3	Sensibilidade ao coeficiente de persistência	88

Lista de Figuras

1	Fluxograma da metodologia experimental	19
2	Distribuição do consumo por edifício.	23
3	Relação entre a temperatura do ar exterior e o consumo normalizado.	24
4	Excerto das séries temporais dos edifícios com maior e menor consumo médio	25
5	Distribuição de densidade dos consumos reais e sintéticos normalizados na zona central.	44
6	Distribuição de densidade dos consumos reais e sintéticos normalizados com maior detalhe da cauda superior.	44
7	Perfil horário e semanal médio dos consumos real e sintético	46
8	Séries reais e sintéticas normalizadas de dois edifícios selecionados pelo menor e maior coeficiente de variação do consumo real.	47
9	Erro de previsão do Prophet por cenário de treino, medido através do NRMSE.	49
10	Erro de previsão do Prophet por cenário de treino, medido através do RMSE.	50
11	Comparação do NRMSE mediano entre os cenários 20% real e 20% real + sintético.	52
12	Distribuição dos ganhos percentuais em NRMSE por edifício e por <i>split</i> no cenário de 20%.	53
13	Comparação do RMSE mediano por <i>split</i> no cenário de 20% de dados reais.	54
14	<i>p</i> -valores combinados pelo método de Fisher nas comparações da previsão.	57
15	Distribuição dos <i>p</i> -valores de Wilcoxon por <i>split</i>	58

Lista de Tabelas

1	Síntese dos principais trabalhos revistos	15
2	Síntese dos dados e critérios de seleção	21
3	Síntese dos cenários experimentais	32
4	Bibliotecas e módulos usados no <i>pipeline</i>	38
5	Métricas de validação do gerador sintético	43
6	Resultados da previsão por cenário	48
7	Síntese dos ganhos no cenário de 20%	54
8	Testes estatísticos da previsão com base no NRMSE	57
9	Resultados da detecção de anomalias	59
10	Inventário dos scripts do <i>pipeline</i>	73
11	Ligação das saídas dos scripts aos elementos dos Capítulos 3 e 4	76
12	Parâmetros e estatísticas de calibração do gerador estatístico-temporal	78
13	Resultados da previsão por <i>split</i>	80
14	Ganhos de NRMSE por edifício no cenário de 20%	82
15	Testes de Wilcoxon da previsão por <i>split</i>	83
16	Deteção de anomalias por cenário e por <i>split</i>	85
17	NRMSE médio dos cenários com complemento sintético por coeficiente de persistência	88

1. Introdução

A monitorização energética dos edifícios enfrenta, com frequência, uma limitação nos dados disponíveis. O registo pode ter começado há pouco tempo ou o período observado pode não abranger todos os modos de funcionamento do edifício.

A presente dissertação foi desenvolvida no âmbito do Mestrado em Informática Aplicada da Escola Superior de Gestão e Tecnologia de Santarém (ESGTS), do Instituto Politécnico de Santarém. O trabalho avalia a inclusão de dados sintéticos no conjunto de treino quando o histórico real é limitado.

O estudo incide sobre duas tarefas da gestão energética de edifícios: a previsão do consumo e a deteção de anomalias. Ambas usam séries temporais, mas o mesmo complemento do treino pode afetar o seu desempenho de forma diferente. O complemento pode reduzir o erro de previsão e, simultaneamente, prejudicar a capacidade do modelo para identificar desvios. É este contraste que orienta o trabalho.

O capítulo apresenta o enquadramento do tema, o problema de investigação, a questão de investigação, os objetivos, os contributos principais e a organização da dissertação.

1.1 Enquadramento

O consumo de energia nos edifícios afeta os custos de operação e o desempenho ambiental das organizações [1,2]. Em edifícios utilizados com regularidade, como escolas, universidades, escritórios ou serviços públicos, o consumo não depende apenas da infraestrutura, mas também dos horários, da ocupação, dos equipamentos, da temperatura exterior e das rotinas de funcionamento.

As séries temporais ajudam a acompanhar a evolução do consumo. Com dados suficientes, é possível observar padrões horários, diferenças entre dias úteis e fins de semana, períodos de maior consumo e desvios face ao comportamento habitual. Quando os registos são cruzados com informação meteorológica, em especial com a temperatura exterior, torna-se mais fácil interpretar parte da variação do consumo [1].

Porém, nem todos os edifícios dispõem de um histórico longo e completo [3]. Nesses casos, o modelo aprende apenas uma parte do comportamento do edifício.

A análise restringiu-se a edifícios da tipologia de educação do Building Data Genome Project 2 (BDG2), para reduzir a heterogeneidade dos padrões de consumo [4]. A previsão do consumo foi feita com o Prophet [5] e a deteção de anomalias com o Isolation Forest [6].

1.2 Problema de Investigação

O problema tratado nesta dissertação não é a falta total de dados, uma vez que os edifícios analisados têm registos de consumo. A dificuldade surge quando existe apenas uma parte inicial da série temporal para treinar os modelos. A janela disponível pode não conter os padrões que só se manifestam mais tarde, como variações de temperatura, diferenças entre semanas, períodos de maior utilização ou alterações sazonais do consumo.

O efeito do histórico curto difere entre as duas tarefas. Na previsão, o erro pode aumentar quando o período de teste contém padrões ausentes da janela de treino. Na deteção de anomalias, uma janela curta pode não representar toda a variação legítima do consumo e levar o modelo a assinalar valores normais como anómalos. Se o treino for reforçado com dados sintéticos cuja dispersão excede a variação normal do edifício, pode ocorrer o efeito contrário: o modelo passa a considerar normal um intervalo de consumos demasiado amplo e deixa de identificar alguns desvios.

Os dados sintéticos acrescentam observações ao treino, mas os parâmetros usados para os gerar são estimados nos edifícios de calibração e não no edifício avaliado. As séries geradas usam a temperatura exterior do *síte* associado ao edifício avaliado e são convertidas para a escala de consumo desse edifício com base na fração de dados reais disponível. Desta forma, preenchem os restantes instantes da janela de treino, mas podem introduzir ritmos ou níveis de consumo que não representam o edifício-alvo.

O estudo compara cenários com diferentes percentagens de dados reais no treino, com e sem reforço sintético. Na previsão, foi ainda incluído um cenário de controlo com ruído branco, que preenche os mesmos instantes do período de treino com valores de consumo aleatórios, ainda que a comparação reflita

também diferenças de amplitude entre os dois complementos. A interpretação deste controlo é discutida na Secção 4.7.

1.3 Questão de Investigação

A dissertação parte da seguinte questão de investigação:

Qual é o efeito dos dados sintéticos, gerados a partir de padrões de um conjunto de edifícios de calibração, no desempenho de modelos de previsão do consumo energético e de deteção de anomalias quando aplicados a edifícios distintos, em cenários de disponibilidade limitada de dados históricos?

1.4 Objetivos

O objetivo geral desta dissertação é avaliar o efeito dos dados sintéticos no desempenho de modelos de previsão do consumo energético e de deteção de anomalias, quando o histórico real disponível para o treino é reduzido. As séries sintéticas são produzidas por um gerador estatístico-temporal, cujos parâmetros são estimados apenas nos dados de treino dos edifícios de calibração.

Para concretizar esse objetivo, o trabalho procurou:

- seleccionar e preparar edifícios com séries temporais de consumo energético e temperatura exterior associada ao respetivo *site*;
- separar os edifícios de calibração dos edifícios de avaliação;
- construir um gerador sintético com base em padrões horários e semanais, temperatura exterior e uma componente residual com dependência temporal;
- comparar os dados sintéticos com os dados reais no espaço normalizado, considerando a distribuição, a dispersão, os valores extremos e a autocorrelação;
- avaliar a previsão do consumo em cenários com 5%, 10% e 20% de histórico real, face a um cenário de referência treinado com o histórico real completo no período de treino;

- comparar, na previsão, o reforço sintético com um cenário de controlo baseado em ruído branco;
- avaliar se a inclusão de dados sintéticos no treino do Isolation Forest altera a *precision*, o *recall* e o F1-score na deteção de anomalias;
- verificar, em cinco *splits*, se a direção e a dimensão das diferenças entre cenários se mantêm quando muda a composição dos grupos de edifícios, recorrendo a testes estatísticos na previsão e a uma comparação descritiva na deteção de anomalias.

1.5 Contributos do trabalho

Os contributos desta dissertação são os seguintes:

- O desenho experimental, que avalia as séries sintéticas pelo efeito da sua inclusão no treino, medido através do erro de previsão e das métricas de deteção de anomalias, em vez de se limitar à sua semelhança com os dados reais;
- A separação entre os edifícios de calibração e os edifícios de avaliação, que permite testar os padrões estimados pelo gerador em edifícios diferentes dos usados na calibração e reduz o risco de repetir no teste padrões já usados na geração;
- O cenário de controlo com ruído branco na previsão do consumo, que compara o complemento sintético com o preenchimento dos mesmos instantes por valores de consumo sem dependência temporal e impede atribuir a redução do erro ao gerador sem essa comparação;
- A avaliação separada da previsão e da deteção de anomalias, que permite obter uma conclusão específica para cada tarefa e modelo, em vez de assumir uma conclusão comum às duas tarefas.

1.6 Estrutura da dissertação

A dissertação está organizada em cinco capítulos. Depois desta introdução, o Capítulo 2 revê o estado da arte, no qual se discutem a gestão energética de edifícios, a previsão do consumo, a escassez de dados, a geração de dados sintéticos, a *data augmentation* e a deteção de anomalias.

O Capítulo 3 descreve a metodologia: o *dataset*, os critérios de seleção dos edifícios, a preparação dos dados, o gerador sintético, os cenários experimentais, os modelos usados e os procedimentos de avaliação.

Por sua vez, o Capítulo 4 apresenta a validação dos dados sintéticos e analisa separadamente o seu efeito na previsão do consumo e na detecção de anomalias. Por fim, o Capítulo 5 retoma a questão de investigação, reúne as principais conclusões, identifica as limitações do estudo e propõe trabalho futuro.

Os apêndices documentam o *pipeline* experimental, as configurações dos modelos e do gerador, bem como os resultados complementares por *split* e por edifício.

2. Estado da Arte

Este capítulo enquadra a dissertação na literatura sobre gestão energética de edifícios, séries temporais de consumo, previsão, escassez de dados, geração de dados sintéticos e deteção de anomalias.

A revisão reúne os trabalhos necessários para analisar o problema central: determinar se, perante um histórico real reduzido, a inclusão de dados sintéticos no treino altera o desempenho da previsão do consumo e da deteção de anomalias.

2.1 Gestão energética e séries de consumo em edifícios

Dispor de registos de consumo não significa conhecer todo o funcionamento energético de um edifício. Um histórico longo permite observar ritmos horários, diferenças entre dias úteis e fins de semana, alterações sazonais e respostas à temperatura exterior. Quando o histórico é curto, alguns desses padrões podem não estar representados na série disponível.

A infraestrutura influencia o consumo energético, mas não o explica na totalidade. A ocupação, os equipamentos instalados, os horários, os sistemas de climatização e as condições exteriores alteram também o perfil de cada edifício. Os registos recolhidos durante o funcionamento normal ajudam a identificar quando a energia é mais utilizada e em que situações a procura aumenta [1].

Nos edifícios de utilização regular, os horários de ocupação e funcionamento produzem padrões recorrentes no consumo. Contudo, pertencer à mesma tipologia não garante perfis semelhantes: dois edifícios de educação podem apresentar níveis, horários de maior consumo e variações semanais diferentes.

A temperatura exterior é analisada em conjunto com o consumo porque ajuda a interpretar a procura associada à climatização [1]. A relação entre temperatura e consumo não é uniforme entre edifícios. A mesma variação de temperatura pode produzir efeitos distintos consoante o isolamento, os sistemas instalados e as regras de funcionamento.

O Building Data Genome Project 2 (BDG2) reúne séries de consumo, informação meteorológica e metadados de um conjunto alargado de edifícios [4]. Esta

composição permite avaliar os modelos em vários edifícios, em vez de limitar a análise a um único caso. Como resulta de recolhas reais, o *dataset* contém falhas, diferenças de cobertura temporal e edifícios com modos de funcionamento distintos.

2.2 Previsão do consumo energético

A previsão do consumo energético estima quanto o edifício consumirá nos períodos seguintes. Essa estimativa apoia o controlo preditivo, a resposta à procura, a avaliação de medidas de eficiência e reabilitação e o planeamento energético a prazo mais longo [1].

A qualidade da previsão depende do histórico usado no treino. O consumo não resulta apenas dos valores das horas ou dos dias anteriores: varia também com a ocupação, os horários e as condições exteriores. Por isso, o modelo tem de aprender os ciclos temporais e responder a alterações que não se repetem com a mesma intensidade em todos os períodos.

Os modelos clássicos de séries temporais, incluindo os modelos autorregressivos e sazonais, representam a dinâmica temporal através de um conjunto reduzido de parâmetros com significado definido [7], o que facilita a interpretação e constitui uma vantagem na comparação de cenários de treino. A sua estrutura mais simples pode, contudo, limitar a representação de relações não lineares e de alterações complexas no funcionamento dos edifícios.

A aprendizagem automática inclui modelos de regressão, árvores de decisão e *random forests*. Zhong et al. [2], por exemplo, propõem uma variante de *support vector regression* baseada em campos vetoriais, que transforma o espaço de atributos para aproximar por uma relação linear a associação não linear entre as variáveis de entrada e o consumo. Estes modelos conseguem representar relações mais complexas, mas continuam dependentes da quantidade e da qualidade do histórico, sobretudo quando a janela de treino é curta.

Os modelos profundos conseguem aprender dependências temporais mais complexas do que os modelos estatísticos convencionais. As redes *Long Short-Term Memory* (LSTM) e *Gated Recurrent Unit* (GRU), por exemplo, exploram a dependência entre observações sucessivas e têm sido aplicadas à previsão do consumo energético [8].

As arquiteturas baseadas em Transformers têm sido exploradas na previsão energética, sem que a utilização de mais parâmetros e mecanismos internos garanta menor erro. Huang e Kaewunruen [9] compararam um Transformer com uma *support vector regression* num edifício público real e obtiveram melhor ajuste com o modelo mais simples. Os modelos orientados a dados dependem também do volume de histórico disponível [3].

Esta dissertação não procura identificar o modelo de previsão com menor erro entre todas as alternativas disponíveis. O objetivo é analisar o que sucede quando o treino é reforçado com dados sintéticos em cenários de histórico reduzido. Um modelo demasiado complexo dificultaria a interpretação, porque uma melhoria poderia resultar tanto dos dados acrescentados como da capacidade do próprio modelo para representar relações temporais complexas.

O Prophet adequa-se a esta comparação porque representa a série através de componentes explícitas de tendência e sazonalidades, numa estrutura aditiva interpretável [5]. Esta decomposição permite comparar os cenários de treino sem depender de representações internas difíceis de interpretar.

2.3 Escassez de dados em séries temporais

Nesta dissertação, a escassez de dados não significa a ausência total de medições, mas um histórico demasiado curto para representar todos os modos de funcionamento do edifício. Treinar com poucos dados significa aprender a partir de uma fração reduzida do funcionamento registado.

Nos edifícios, um histórico curto pode incluir apenas parte dos ciclos horários, semanais e sazonais do consumo [3]. Podem faltar fins de semana suficientes, períodos com temperaturas mais extremas, épocas de maior ocupação ou alterações legítimas nos horários e na utilização do edifício.

A falta de representatividade afeta as duas tarefas de forma diferente. Na previsão, os padrões ausentes do treino podem aumentar o erro no período de teste. Na deteção de anomalias, é mais crítica porque a janela inicial define os valores e as variações que o modelo considera normais.

A literatura propõe várias estratégias para lidar com o histórico curto. Li et al. [3] comparam a geração de dados, o *incremental learning*, a *transfer learning* e abordagens *physics-informed* em cenários de escassez extrema, acentuada e mode-

rada. Nesse estudo, realizado no BDG2, a geração de dados obteve o melhor desempenho entre as quatro estratégias nos cenários de escassez extrema e acentuada. A comparação não incluiu um complemento de consumo aleatório, como o controlo usado nesta dissertação.

Pinto et al. [10] sistematizam a aplicação de *transfer learning* numa revisão crítica de 77 trabalhos sobre edifícios. Xing et al. [11] integram uma análise de semelhança na previsão para selecionar edifícios de origem semelhantes ao edifício-alvo.

Estas estratégias exigem condições que não correspondem ao problema estudado nesta dissertação. A *transfer learning* requer edifícios de origem semelhantes ao edifício-alvo para reduzir o risco de transferência negativa. Pinto et al. [10] identificam a necessidade de métodos consistentes para medir essa semelhança. O *incremental learning* pressupõe a chegada contínua de novos dados reais para reajustar o modelo [3], enquanto neste estudo existe apenas uma janela inicial fixa.

As abordagens *physics-informed* mais completas exigem informação térmica e operacional por edifício, como os equipamentos instalados e os modos de funcionamento, que o BDG2 não disponibiliza. No estudo de Li et al. [3], a estratégia *physics-informed* foi implementada através da decomposição estatística do consumo em valor médio e flutuação. Entre as quatro estratégias comparadas, obteve o melhor resultado apenas no cenário de escassez moderada, e não nos cenários de histórico mais curto que interessam a este trabalho.

Esta dissertação explora a geração de dados sintéticos porque permite reforçar o treino sem esperar pela recolha gradual de novas medições.

Contudo, a geração de dados não resolve a falta de representatividade do histórico. Os parâmetros são estimados em edifícios de calibração da mesma tipologia, mas os modelos são avaliados noutros edifícios. A capacidade de transferir esses padrões para edifícios distintos constitui uma limitação.

2.4 Dados sintéticos e *data augmentation*

Os dados sintéticos só são úteis se acrescentarem ao treino padrões que melhorem o desempenho na tarefa final, pois a semelhança visual ou estatística com os dados reais não é suficiente [12]. No consumo energético, devem ainda ser

avaliados a ordem dos registos, os ciclos diários e semanais, a autocorrelação, os valores extremos e a relação com variáveis externas, como a temperatura [13].

Acrescentar estas séries ao treino constitui uma forma de *data augmentation*, usada quando o histórico real é curto ou pouco representativo. Nas séries temporais, aumentar o número de observações não garante que sejam acrescentados novos ciclos, dependências ou variações úteis para o modelo.

A geração de séries temporais recorre a métodos simples, baseados em perturbações, janelas ou deformações temporais [14], e a métodos estatísticos e autorregressivos, que modelam explicitamente a estrutura temporal da série [13]. A estes juntam-se abordagens que recorrem à simulação física do edifício [15], modelos generativos profundos e soluções híbridas que combinam simulação e modelos generativos [16]. Estes métodos diferem no grau de semelhança com os dados reais, no controlo sobre as componentes geradas, na quantidade de dados exigida e no custo computacional.

Fang et al. [15] ampliam o treino com dados de comportamento de ocupação gerados por simulação física, para prever consumos fora do intervalo observado no histórico. Kang e Song [17] decompõem as séries de entrada em componentes temporais e usam-nas como variáveis adicionais, no caso dos edifícios novos, cujo histórico inicial é reduzido. Fu et al. [18] recorrem a modelos generativos profundos para gerar séries condicionadas por metadados do edifício. Nenhum destes trabalhos compara as séries acrescentadas ao treino com o preenchimento dos mesmos instantes por valores de consumo sem dependência temporal.

A comparação com uma referência simples é uma prática reconhecida na avaliação empírica em aprendizagem automática. Lipton e Steinhardt [19] observam que, quando uma melhoria resulta de várias alterações combinadas, é frequente não se identificar qual delas a produz, e que a ausência de estudos de ablação esconde a origem do ganho. Ferrari Dacrema et al. [20] ilustram o risco: de dezoito métodos de recomendação baseados em redes neuronais apresentados em conferências de referência, apenas sete foram reproduzíveis com esforço razoável e seis desses foram frequentemente superados por heurísticas simples bem afinadas. Na deteção de anomalias em séries temporais, Kim et al. [21] mostram que um protocolo de avaliação comum pode atribuir a um detetor aleatório um desempenho comparável ao do estado da arte. Nestes casos, um valor de referência sem a propriedade em estudo torna possível distinguir o efeito dessa

propriedade do efeito do procedimento. O cenário de controlo com ruído branco desta dissertação segue essa lógica: preenche a mesma janela de treino com valores de consumo aleatórios, o que permite comparar o contributo da estrutura das séries geradas com o contributo da simples reposição da janela de treino com mais observações.

Entre os métodos que exigem mais dados encontram-se as redes generativas adversariais (GAN), os *autoencoders* variacionais e os modelos de difusão. Estes modelos podem produzir séries realistas, mas são difíceis de treinar e as séries geradas nem sempre mantêm a qualidade esperada, sobretudo no caso das GAN [13, 14]. As variantes condicionadas exigem também metadados por edifício, como demonstra o modelo de difusão de Fu et al. [18].

Os métodos estatísticos e autorregressivos seguem o caminho inverso: representam a série através de componentes estimadas separadamente, como o perfil horário e semanal, a resposta a variáveis externas e um resíduo com dependência temporal [7]. Kang, Hyndman e Li [22] geram séries com características controláveis a partir de modelos autorregressivos de mistura e de um número reduzido de parâmetros, ainda que o propósito desse trabalho seja produzir séries de referência para avaliar métodos de previsão e classificação, e não complementar históricos curtos. A calibração exige poucos dados e cada componente é fixada de forma explícita. Em contrapartida, a estrutura das séries geradas limita-se à que for assumida na formulação: relações não lineares e alterações no funcionamento do edifício que não estejam previstas nas componentes não são reproduzidas.

A dimensão do conjunto de calibração limita os métodos que podem ser usados. O gerador desta dissertação é calibrado com sete edifícios e apenas com a parte de treino das respetivas séries. Fu et al. [18], em contraste, treinam o modelo de difusão condicionada com 1828 contadores do BDG2. A esta restrição acresce um segundo critério: a transparência do gerador.

Um gerador estatístico-temporal é transparente, pois conhecem-se as componentes que introduz na série, ou seja, o perfil horário e semanal, o efeito da temperatura exterior e a componente residual com dependência temporal. A transparência permite interpretar uma eventual diferença face ao controlo: se as componentes do gerador não fossem conhecidas, essa diferença não poderia ser associada a nenhuma delas. Além disso, este cenário de controlo poderia acom-

panhar qualquer gerador, porque atua apenas sobre os valores acrescentados ao treino.

Uma série sintética pode aproximar-se das séries reais na média, na dispersão ou na distribuição e, ainda assim, não produzir o mesmo efeito nas duas tarefas; a semelhança estatística e a utilidade na tarefa final são propriedades distintas [23]. Na previsão, o complemento preenche uma parte maior da janela de treino e fornece ao Prophet mais instantes para estimar a tendência e as sazonalidades. Na deteção de anomalias, a dispersão das séries acrescentadas pode atuar em sentido contrário, como se detalha na Secção 2.5.

A cobertura temporal e a dispersão são propriedades diferentes do mesmo complemento: um complemento pode preencher mais horas, dias e meses sem representar corretamente a variação normal do edifício. Por isso, a avaliação é feita em separado para cada tarefa, com as séries geradas a entrar apenas como complemento do histórico real. Na previsão, essa avaliação inclui um cenário de controlo que acrescenta o mesmo número de observações sem estrutura temporal no consumo, adotado apenas nesta tarefa.

2.5 Deteção de anomalias no consumo energético

Na deteção de anomalias, não basta procurar valores pouco frequentes: é necessário definir os consumos e as variações que o modelo considera normais. Nesta dissertação, os dados sintéticos reforçam apenas esse conjunto de treino normal e não representam exemplos de falhas.

Um desvio no consumo pode ter origem numa avaria, num erro de sensor ou numa alteração de utilização, mas o consumo também varia por razões legítimas, como a ocupação, a temperatura ou horários especiais. Separar uma anomalia real de uma variação aceitável nem sempre é imediato [24].

Em muitos edifícios não existe uma identificação completa dos períodos anómalos, o que reduz a viabilidade dos métodos supervisionados e dificulta a avaliação dos resultados [24]. A própria avaliação da deteção de anomalias em séries temporais tem sido objeto de crítica: Wu e Keogh [25] identificam falhas recorrentes nos conjuntos de referência usados na área, a que se soma a fragilidade dos protocolos de avaliação discutida na Secção 2.4. Nestas condições, a comparação apoia-se frequentemente em cenários controlados, regras de referência ou ano-

malias introduzidas artificialmente. A introdução de anomalias conhecidas não substitui a validação com falhas reais, mas permite calcular as métricas e comparar os cenários de treino em condições equivalentes; alguns estudos de avaliação recorrem a conjuntos de tipos de anomalias definidos para esse efeito [26].

Sem essa identificação, são frequentemente usados métodos não supervisionados, que incluem abordagens baseadas em distância e densidade, reconstrução e classificação de uma classe [24].

O Isolation Forest isola observações que se afastam da maioria e que, por serem menos frequentes, exigem menos divisões para serem separadas [6]. O método não depende de medidas de distância ou densidade, aceita várias variáveis de entrada e pode ser treinado sem exemplos de anomalias. Estas propriedades permitem comparar os cenários desta dissertação, nos quais o treino contém apenas valores considerados normais.

Os dados sintéticos podem alterar os limites do consumo que o modelo considera normal. Se as séries acrescentadas forem demasiado dispersas, o Isolation Forest pode aceitar um intervalo de consumos mais amplo e deixar de identificar alguns desvios. Se representarem melhor a variação normal do edifício, podem produzir o efeito contrário. São duas hipóteses sobre a alteração da região considerada normal, cuja verificação exigiria um cenário de controlo.

Alguns estudos usam dados sintéticos para acrescentar falhas ou situações raras ao treino. Han e Chong [16] combinam simulação física e redes generativas adversariais para gerar exemplos de falhas. Tian et al. [27] recorrem à sobreamostragem sensível à densidade e a uma codificação posicional melhorada para aumentar a representação de anomalias no consumo energético. Esses estudos reforçam os exemplos anómalos, enquanto esta dissertação reforça apenas os exemplos considerados normais.

Por isso, importa determinar se esse reforço do comportamento normal ajuda o Isolation Forest a identificar desvios ou se reduz a capacidade de deteção.

2.6 Posicionamento dos modelos usados

A seleção do Prophet e do Isolation Forest obedeceu a um critério comum: privilegiar modelos cujas componentes são conhecidas, para que uma diferença entre cenários de treino possa ser atribuída aos dados acrescentados e não à

capacidade do próprio modelo para representar relações temporais complexas. Na previsão, esse critério afastou as arquiteturas mais expressivas revistas na Secção 2.2. Na deteção de anomalias, conduziu a um método que dispensa exemplos de falhas, entre as abordagens não supervisionadas revistas na Secção 2.5.

Os dois modelos partilham a mesma limitação: nenhum foi escolhido por apresentar o menor erro de previsão ou o melhor F1-score entre as alternativas disponíveis. Os resultados descrevem, por isso, o comportamento destes dois modelos perante os cenários de treino comparados e não constituem uma regra para todos os métodos de previsão ou de deteção de anomalias.

2.7 Síntese da literatura revista

A literatura revista mostra que a previsão do consumo e a deteção de anomalias dependem da quantidade e da qualidade do histórico. Quando a série é curta ou incompleta, o modelo aprende apenas parte do comportamento energético do edifício. Na previsão, o erro aumenta; na deteção de anomalias, altera-se a forma como a normalidade é aprendida.

A inclusão de dados sintéticos pode reforçar o treino, mas o efeito dessa inclusão tem de ser avaliado separadamente em cada tarefa. Um complemento que reduz o erro de previsão pode não ajudar a identificar desvios.

Na geração sintética, a avaliação recai principalmente na fidelidade estatística das séries produzidas, isto é, na proximidade em relação às reais em distribuição, dispersão ou autocorrelação. Numa revisão de 169 trabalhos sobre séries energéticas sintéticas, a fidelidade estatística representa 79,9% das avaliações realizadas, contra 4,7% dedicadas à utilidade das séries geradas na tarefa a que se destinam [13]. Menos frequente é medir a utilidade na tarefa final, treinando os modelos com dados sintéticos e testando-os em medições reais. Stenger et al. [12] colocam esta distinção no centro da avaliação. Persistem, além disso, duas outras lacunas: raramente se distingue se um ganho decorre da estrutura temporal introduzida ou da reposição da janela de treino com mais observações, e raramente se verifica se o mesmo reforço pode beneficiar uma tarefa e prejudicar outra.

A dissertação responde a estas três limitações através das opções metodológi-

cas apresentadas no Capítulo 3: a avaliação pelo desempenho na tarefa final, o cenário de controlo com ruído branco na previsão e a comparação do mesmo complemento nas duas tarefas.

A Tabela 1 sintetiza os trabalhos revistos, a limitação relevante de cada um para este estudo e a respetiva ligação à dissertação.

Tabela 1: Síntese dos principais trabalhos revistos

Referência	Tema	Abordagem	Limitação relevante	Ligação à dissertação
Zhang et al. [1]	Previsão energética em edifícios	Revisão de métodos de aprendizagem automática	Foco amplo na previsão, sem tratar diretamente o reforço sintético em cenários de escassez	Documenta a dependência da previsão em relação à quantidade e à qualidade dos dados
Miller et al. [4]	Building Data Genome Project 2	<i>Dataset</i> real de consumo e meteorologia em edifícios	Heterogeneidade, falhas e diferenças entre edifícios	Disponibiliza os dados reais de consumo e temperatura usados nas experiências
Taylor e Letham [5]	Prophet	Modelo com tendência, sazonalidades e efeitos de calendário	Não representa todos os comportamentos complexos das séries energéticas	Fundamenta a utilização do Prophet como modelo interpretável na comparação dos cenários de treino
Zhong et al. [2]	Previsão energética	<i>Support vector regression</i>	Dependência da quantidade e da qualidade do histórico	Apresenta uma alternativa de aprendizagem automática cuja eficácia também depende do histórico disponível

Tabela 1 — continuação

Referência	Tema	Abordagem	Limitação relevante	Ligação à dissertação
Oliveira e Oliveira [8]; Huang e Kawunruen [9]	Modelos profundos e Transformers	Arquiteturas mais expressivas	Maior necessidade de dados e menor interpretabilidade	Documenta modelos mais complexos e sustenta a escolha de um modelo mais simples, para não confundir o efeito dos dados acrescentados com a capacidade do modelo
Li et al. [3]	Escassez de dados	Geração de dados, <i>transfer learning</i> , <i>incremental learning</i> e abordagens <i>physics-informed</i>	Nenhuma solução elimina totalmente o problema da representatividade	Compara quatro estratégias para lidar com histórico curto no mesmo <i>dataset</i> usado nesta dissertação
Pinto et al. [10]; Xing et al. [11]	Transferência entre edifícios	<i>transfer learning</i> e análise de semelhança	Exige edifícios de origem semelhantes	Documenta o risco de transferência negativa quando os edifícios de origem e de destino diferem
Fang et al. [15]; Kang e Song [17]	Reforço de dados (<i>data augmentation</i>) na previsão energética	Fang et al.: simulação física baseada no comportamento de ocupação; Kang e Song: decomposição multivariada em componentes temporais	Não incluem um cenário de controlo sem dependência temporal que permita distinguir o contributo específico do reforço	Situa o reforço sintético do treino em cenários de histórico curto

Tabela 1 — continuação

Referência	Tema	Abordagem	Limitação relevante	Ligação à dissertação
Kang, Hyndman e Li [22]	Geração estatística de séries temporais	Modelos autorregressivos de mistura com características controláveis e poucos parâmetros	Concebido para gerar séries de referência na avaliação de métodos, não para complementar históricos curtos	Ilustra a geração estatística transparente, na mesma família do gerador desta dissertação
Iglesias et al. [14]; Stenger et al. [12]	<i>Data augmentation</i> e séries sintéticas	Revisões e taxonomias	A semelhança estatística não garante utilidade prática	Sustenta a avaliação dos dados sintéticos pelo desempenho na tarefa final
Turowski et al. [13]; Fu et al. [18]	Séries energéticas sintéticas	Métodos estatísticos, generativos e difusão condicionada	Métodos complexos exigem mais dados, metadados e computação	Mostra que os modelos generativos profundos exigem mais dados e metadados do que os disponíveis na calibração
Himeur et al. [24]; Liu et al. [6]	Deteção de anomalias	Revisão de anomalias e Isolation Forest	Dificuldade em definir o comportamento normal sem identificação completa das anomalias	Fundamenta o uso de um método não supervisionado no treino apenas com valores considerados normais
Han e Chong [16]; Tian et al. [27]	Dados sintéticos para falhas e anomalias	GAN, simulação e sobreamostragem	Foco em gerar ou reforçar situações raras	Distingue o reforço de exemplos anómalos do reforço do comportamento normal adotado nesta dissertação

3. Metodologia

3.1 Enquadramento metodológico

Este capítulo descreve o procedimento seguido para avaliar o efeito dos dados sintéticos em duas tarefas da gestão energética de edifícios: a previsão do consumo e a deteção de anomalias.

O estudo considerou cenários em que apenas a parte inicial do consumo real estava disponível para o treino. Os dados sintéticos preencheram apenas os restantes instantes do período de treino e nunca substituíram os valores reais disponíveis. A avaliação incidiu sempre no consumo real do período de teste. O objetivo foi medir se o complemento alterava o erro de previsão e as métricas de deteção de anomalias quando o histórico real era limitado, e não demonstrar que as séries geradas reproduziam cada edifício.

O desenho experimental assenta em três decisões principais:

- estimar os parâmetros do gerador apenas nos edifícios de calibração, sem usar o consumo dos edifícios avaliados, para reduzir o risco de validação circular;
- definir os cenários de escassez respeitando a ordem temporal das séries, como aconteceria num edifício com monitorização recente;
- repetir as experiências com cinco sementes, para verificar se a direção e a dimensão das diferenças entre cenários mudavam com a composição dos grupos de edifícios.

Depois da calibração, as séries geradas foram comparadas com o consumo real dos edifícios de avaliação. Os resultados desta comparação serviram apenas para caracterizar o gerador e não foram usados para reajustar os seus parâmetros.

Na previsão, foi ainda incluído um cenário de controlo com ruído branco, detalhado na Secção 3.8.

A Figura 1 apresenta o fluxograma do processo. A região tracejada delimita o ciclo

executado pelo script `10.multiplas_execucoes.py`. Esse ciclo inclui a seleção e divisão dos edifícios, a preparação dos dados, a aplicação do gerador sintético e as duas tarefas experimentais: a previsão do consumo e a detecção de anomalias.

A análise por edifício, os testes estatísticos e as tabelas finais foram produzidos a partir dos resultados reunidos das cinco execuções. A análise exploratória e a validação do gerador foram executadas uma única vez no *split* 500.




Figura 1: Fluxograma da metodologia experimental.

3.2 Dataset utilizado

O estudo foi desenvolvido com o Building Data Genome Project 2 (BDG2), um *dataset* público usado na análise energética de edifícios [4]. O *dataset* reúne séries temporais de consumo, informação meteorológica e metadados associados a edifícios de diferentes locais.

Foram usados dois ficheiros principais. O ficheiro `electricity_cleaned.csv` contém os valores de consumo elétrico. O ficheiro `weather.csv` contém a informação meteorológica por *site* e por instante temporal. Como os identificadores dos edifícios incluem informação sobre o *site* e a tipologia funcional, foi possível ligar cada edifício à respetiva meteorologia.

A análise restringiu-se aos edifícios da tipologia de educação. A restrição reduziu a heterogeneidade funcional da amostra, evitando comparar diretamente edifícios com utilizações muito diferentes. Mesmo assim, os edifícios selecionados continuaram a apresentar diferenças na escala, na dispersão e na evolução temporal do consumo.

O inventário dos scripts, as respetivas funções e a sequência de execução do *pipeline* são apresentados no Apêndice A.

3.3 Seleção dos edifícios

A seleção dos edifícios seguiu três critérios: a qualidade das séries temporais, a tipologia funcional e a diversidade por *site*.

Numa primeira fase, foi calculada a percentagem de valores em falta em cada série de consumo. Foram considerados apenas os edifícios com menos de 5% de valores ausentes. Em seguida, os identificadores válidos foram separados em três componentes, correspondentes ao *site*, ao tipo de uso e ao nome do edifício. Esta separação permitiu manter apenas os edifícios associados à tipologia de educação.

O ficheiro de consumo continha 1 578 edifícios, cada um com 17 544 registos horários entre 1 de janeiro de 2016 e 31 de dezembro de 2017. O critério de menos de 5% de valores em falta reduziu o conjunto para 1 019 edifícios, e a restrição à tipologia de educação deixou 405 edifícios elegíveis, distribuídos por 11 *sites*.

Sempre que possível, foi selecionado inicialmente um edifício por *site*, para não concentrar a amostra em poucos *sites*. Quando esta regra não permitia reunir os doze edifícios necessários, foram acrescentados outros edifícios da mesma tipologia.

Depois da seleção, os edifícios foram ordenados aleatoriamente com a semente definida para cada execução e divididos em dois grupos. O primeiro reuniu sete edifícios de calibração, usados para estimar os parâmetros do gerador sintético. O segundo reuniu cinco edifícios de avaliação, mantidos fora da calibração do gerador. Nestes cinco edifícios, a parte de treino foi usada para treinar os modelos e a parte de teste permaneceu reservada à avaliação. Cada repartição é designada, ao longo da dissertação, por *split*.

Os valores em falta das séries escolhidas foram de seguida preenchidos por interpolação temporal, mas apenas em lacunas com até seis valores horários consecutivos. Em lacunas mais longas, só as primeiras seis horas foram preenchidas e os restantes valores permaneceram em falta.

Após a interpolação, voltou-se a calcular a percentagem de valores ausentes. O limite de 2% funcionou como critério de validação da amostra já selecionada e como critério de substituição de edifícios. Se a percentagem de valores em falta de algum dos doze edifícios o ultrapassasse, a execução do *split* era interrompida. Nas cinco execuções realizadas, nenhum edifício foi excluído nesta fase.

A separação entre os edifícios de calibração e os edifícios de avaliação foi mantida durante todo o *pipeline*, evitando que o consumo dos edifícios avaliados fosse usado para estimar os parâmetros do gerador.

A Tabela 2 apresenta uma síntese dos dados e dos critérios de seleção.

Tabela 2: Síntese dos dados e critérios de seleção

Elemento	Definição usada
<i>Dataset</i>	Building Data Genome Project 2
Ficheiro de consumo	electricity_cleaned.csv
Ficheiro meteorológico	weather.csv
Tipologia analisada	Educação
Variável de consumo	consumo_kwh
Variável meteorológica	temperatura_ar_exterior, obtida a partir de airTemperature
Critério inicial de valores em falta	Menos de 5% por edifício
Interpolação aplicada	Interpolação temporal limitada a seis valores horários consecutivos por lacuna
Critério após interpolação	Menos de 2% de valores em falta
Edifícios por <i>split</i>	7 edifícios de calibração e 5 edifícios de avaliação
Divisão temporal	70% da série para treino e 30% para teste
Sementes dos <i>splits</i>	42, 100, 200, 400 e 500

3.4 Preparação do *dataset* de modelação

Antes da modelação, os dados de consumo foram reorganizados. Para juntar o consumo à meteorologia, cada linha tinha de conter o identificador do edifício, o instante temporal e o respetivo valor de consumo. Os dados foram, por essa razão, convertidos para formato longo.

O ficheiro meteorológico não organiza os registos por edifício, mas por *site* e por *timestamp*. O *site* foi retirado diretamente do identificador de cada edifício.

A junção foi feita através do *timestamp* e do *site*. Com esta junção, cada valor de consumo ficou associado à temperatura registada no mesmo local e no mesmo momento.

Das variáveis meteorológicas disponíveis, foi usada apenas a temperatura do ar exterior. No *dataset* original, essa variável surge como `airTemperature`. No *pipeline*, passou a chamar-se `temperatura_ar_exterior`.

No final, foram removidas as observações sem valor de consumo ou sem valor de temperatura. Esses registos não podiam ser usados nem no treino nem na avaliação. Depois da limpeza, o *dataset* foi ordenado por edifício e por instante temporal.

No *split* 500, a junção cobriu 99,55% das observações com temperatura associada e a remoção dos registos incompletos eliminou 0,70% das linhas.

3.5 Análise exploratória inicial

A análise exploratória incidiu sobre os dados reais de um único *split*, correspondente à semente 500. Foram estudadas a distribuição do consumo, as diferenças entre edifícios, a evolução temporal e a relação com a temperatura exterior. Esta análise não foi usada para ajustar o coeficiente de persistência da componente residual nem o limite do coeficiente térmico. As experiências finais foram, posteriormente, repetidas nos cinco *splits*, incluindo o próprio *split* 500.

Como os edifícios tinham consumos médios diferentes, os valores foram normalizados por edifício para impedir que os edifícios com maior consumo dominassem a análise conjunta.

A Figura 2 mostra a distribuição do consumo por edifício. As diferenças de escala entre edifícios justificaram a utilização de uma escala logarítmica no eixo vertical.




Figura 2: Distribuição do consumo por edifício.

A Figura 3 mostra uma correlação de Pearson desprezável entre a temperatura exterior e o consumo normalizado, próxima de zero neste conjunto de edifícios. A temperatura foi mantida porque a literatura documenta a sua relação com as cargas de climatização [1]. Como o BDG2 disponibiliza uma série meteorológica por *site*, e não por edifício, todos os edifícios do mesmo *site* receberam os mesmos valores de temperatura. A correlação agregada caracteriza este conjunto de dados, mas não demonstra que a temperatura seja dispensável em cada edifício.




Figura 3: Relação entre a temperatura do ar exterior e o consumo normalizado.

A Figura 4 compara os edifícios com maior e menor consumo médio. Mesmo dentro da tipologia de educação, os edifícios diferem no nível de consumo e na forma como esse consumo varia ao longo do tempo. A avaliação foi, por isso, realizada também por edifício e por *split*, e não apenas através de médias agregadas.




Figura 4: Excerto das séries temporais dos edifícios com maior e menor **consumo médio**.

3.6 Geração de dados sintéticos

3.6.1 Princípio geral do gerador

O gerador foi construído para produzir séries de consumo normalizado nos edifícios de avaliação a partir de parâmetros estimados nos edifícios de calibração. Não corresponde a uma simulação física de cada edifício e não usa informação sobre equipamentos, ocupação, materiais construtivos ou sistemas de climatização.

O método pertence às abordagens que geram novas sequências a partir de padrões medidos e preservam explicitamente a ordem temporal e a dependência entre observações [13, 14].

O consumo sintético foi construído a partir de três componentes. O perfil horário e semanal representa a variação média por hora do dia e por dia da semana. A componente térmica multiplica esse perfil por um valor calculado a partir da temperatura exterior. A componente residual AR(1) introduz dependência entre resíduos consecutivos.

Como os edifícios não tinham a mesma escala de consumo, a geração foi feita primeiro no espaço normalizado.

De forma simplificada, o consumo sintético normalizado foi obtido pela combinação multiplicativa das três componentes:

$$\begin{aligned}\eta_t &\sim \mathcal{N}(0, \sigma_{\text{res}}^2 (1 - \varphi^2)) \\ e_0 &= \eta_0 \\ e_t &= \varphi e_{t-1} + \eta_t, \quad t > 0, \quad \varphi = 0,85 \\ R(t) &= \max(1 + e_t, 0,1) \\ T(t) &= \max(\beta \cdot \text{Temp}(t) + \alpha, 0,1) \\ C_{\text{sint, norm}}(t) &= P(h_t, d_t) \cdot T(t) \cdot R(t)\end{aligned}$$

Nesta formulação, $P(h_t, d_t)$ representa o perfil médio associado à hora do dia (h_t) e ao dia da semana (d_t). A variável $\text{Temp}(t)$ corresponde à temperatura exterior. Os parâmetros α e β resultam do ajuste linear da razão entre o consumo normalizado e o perfil horário e semanal em função da temperatura. O parâmetro β é o declive, traduz a sensibilidade térmica e foi limitado ao intervalo entre $-0,05$ e $0,05$. O parâmetro α é a ordenada na origem e fixa o nível do ajuste quando o efeito da temperatura é nulo.

O pseudocódigo do gerador estatístico-temporal e a síntese dos respetivos parâmetros são apresentados no Apêndice B.

3.6.2 Divisão temporal das séries

A divisão temporal foi feita em cada edifício, respeitando a ordem dos registos. Os primeiros 70% da série foram reservados para treino. Os restantes 30% constituíram o conjunto de teste.

Nos edifícios de calibração, apenas a parte de treino foi usada para estimar os parâmetros do gerador sintético. Nos edifícios de avaliação, a mesma divisão separou os dados disponíveis para treinar os modelos dos dados reais usados na avaliação. O período de teste permaneceu sempre real.

A divisão não foi feita por uma data comum a todos os edifícios, mas pela posição

dos registos dentro de cada série. A proporção manteve-se, deste modo, em todos os edifícios, mesmo quando as séries tinham durações ou períodos de cobertura diferentes.

3.6.3 Perfil horário e semanal

Para calcular o perfil horário e semanal, usou-se apenas o período de treino dos edifícios de calibração.

Antes do cálculo, o consumo de cada edifício foi dividido pela sua média. A normalização impediu que os edifícios com maior escala tivessem mais peso no perfil calculado a partir de todos eles.

Em seguida, foi calculado o consumo médio para cada hora do dia e para cada dia da semana. Desse cálculo resultou um perfil que resume os ritmos observados nos edifícios usados na calibração.

Por fim, aplicou-se uma média móvel centrada de largura 3 ao longo das horas do dia, dentro de cada dia da semana. A suavização reduziu diferenças pontuais entre horas consecutivas sem misturar dias distintos nem alterar a forma geral do perfil diário.

3.6.4 Efeito térmico

Depois do perfil horário e semanal, foi acrescentado o efeito da temperatura exterior. Para isso, calculou-se a razão entre o consumo normalizado observado e o perfil temporal já estimado. Ajustou-se em seguida um modelo linear simples entre essa razão e a temperatura do ar.

O coeficiente térmico foi limitado ao intervalo entre $-0,05$ e $0,05$, para impedir que um ajuste extremo fizesse a temperatura dominar a geração. O gerador foi recalibrado em cada *split* e, nas cinco calibrações, o declive estimado variou entre $-0,00197$ e $0,00245$, com três valores positivos e dois negativos. O maior em módulo ficou cerca de vinte vezes abaixo do limite de $0,05$, que nunca chegou a atuar: o contributo reduzido da temperatura decorre da magnitude dos declives e não do corte imposto. Na calibração do *split* 500, usada na análise exploratória e na validação, o declive foi de $-0,00197$. A Tabela 12 reúne os valores das cinco calibrações.

Foi definido um valor mínimo de $0,1$ para a componente térmica e para a compo-

nente residual, o que impediu valores nulos ou negativos nessas componentes. Na calibração, o mesmo mínimo foi aplicado ao perfil horário e semanal, que aí surge como denominador no cálculo do resíduo, evitando divisões por valores próximos de zero. Na geração das séries sintéticas, o perfil entra apenas como fator multiplicativo e não é truncado; os pares hora/dia sem correspondência no perfil recebem o valor 1,0.

A componente térmica foi estimada apenas com os dados de treino dos edifícios de calibração. Na geração, a temperatura entra através do fator multiplicativo $T(t)$ e não determina isoladamente o consumo sintético.

3.6.5 Componente residual e processo AR(1)

Depois de aplicar o perfil horário e semanal e o ajuste térmico, a diferença relativa entre o consumo observado e o valor estimado foi usada como resíduo.

Os resíduos dos edifícios de calibração parametrizaram um processo autorregressivo de primeira ordem, AR(1), aplicado às séries dos edifícios de avaliação. O coeficiente de persistência foi fixado em 0,85. O termo e_t representa o desvio relativo entre o consumo real e o consumo estimado pelas componentes horária e térmica. O ruído de inovação η_t foi dimensionado para que o processo, depois de estabilizar e antes de lhe ser aplicado o mínimo de 0,1, tivesse o mesmo desvio-padrão dos resíduos de calibração [7].

O valor de 0,85 situa-se na gama alta de persistência e reflete a dependência forte entre observações consecutivas própria de séries de consumo horário. Foi fixado a priori, sem estimar um coeficiente específico para cada edifício, para não ajustar o gerador aos dados de calibração. A dependência temporal resultante foi avaliada comparando a autocorrelação das séries reais e sintéticas até 48 desfasamentos. O efeito da escolha deste valor nos resultados da previsão é avaliado na Secção C.5, onde se verifica que a conclusão principal se mantém para outros coeficientes.

3.6.6 Aplicação aos edifícios *held-out*

Nos edifícios de avaliação, o gerador combinou o perfil horário e semanal e os parâmetros α e β , obtidos nos edifícios de calibração, com a temperatura exterior do *site* do próprio edifício de avaliação. A componente residual não foi transportada da calibração: para cada edifício de avaliação foi simulada uma nova realização

do processo AR(1) descrito na Secção 3.6.5. O resultado foi guardado na variável `consumo_sintetico_normalizado`.

Nesta fase, os valores sintéticos permaneceram normalizados. A conversão para a escala de consumo de cada edifício foi realizada separadamente em cada cenário, usando apenas a fração de dados reais disponível nesse cenário.

Nos cenários de 5%, 10% e 20%, nenhum valor de consumo real fora da fração disponível entrou no treino. A escala usada na conversão correspondeu à mediana das medianas horárias do consumo real disponível; quando existiam menos de 24 observações, foi usada a mediana simples. Como o perfil sintético foi normalizado pela média dos edifícios de calibração e convertido através de uma mediana do edifício avaliado, a média e a mediana podem produzir níveis diferentes em séries assimétricas.

A temperatura exterior seguiu uma regra diferente. O gerador usou a temperatura real do *site* do edifício-alvo para produzir as séries sintéticas em todo o período de treino, incluindo os instantes em que o consumo real foi tratado como indisponível. O Prophet usou-a como regressor externo conhecido, tanto no período de treino como no de teste. O Isolation Forest não usou a temperatura entre as suas variáveis de entrada. Assim, não existe *data leakage* do teste para o treino, nem do edifício avaliado para a calibração do gerador, embora a série meteorológica do *site* seja assumida como disponível no período de treino e no de teste.

3.7 Validação dos dados sintéticos

O gerador foi avaliado num diagnóstico separado das experiências finais. A validação corresponde a um único *split*, o da semente 500, e incidiu sobre o período de treino dos cinco edifícios de avaliação desse *split*. Esses edifícios integram também as experiências finais, pelo que a caracterização do gerador não é feita num conjunto de edifícios independente do avaliado. O objetivo não foi provar que as séries reais e sintéticas eram iguais, mas caracterizar as diferenças entre ambas antes de utilizar os dados gerados como complemento do treino. A validação foi feita no espaço normalizado, para permitir a comparação entre edifícios com escalas diferentes, seguindo a ideia de que as séries sintéticas devem ser avaliadas em várias dimensões, incluindo distribuição, valores extremos e dependência temporal [12, 13].

Na comparação foram usadas a média, o desvio-padrão, o percentil 99, a raiz do erro quadrático médio (RMSE) e a estatística de Kolmogorov-Smirnov de duas amostras (KS) [28]. A média avaliou o nível global das séries; o desvio-padrão, a dispersão; o percentil 99, os valores superiores; o RMSE mediu a diferença ponto a ponto; e a estatística KS, a diferença entre distribuições. Cada métrica foi calculada por edifício e agregada pela média entre os cinco edifícios. Também foi registada a proporção de edifícios em que o teste KS rejeitou a igualdade das distribuições ao nível de 5%, retomada no capítulo seguinte.

No teste de Kolmogorov-Smirnov, a comparação foi feita sobre subamostras aleatórias de até 1 000 observações por edifício, com semente fixa, para manter a reprodutibilidade e limitar a sensibilidade do teste à dimensão da amostra. Sobre a série de treino completa, o valor crítico a 5% desceria para cerca de 0,017, e o teste passaria a rejeitar diferenças sem relevância prática; com 1 000 observações por amostra, esse valor é de aproximadamente 0,061.

Também foi analisada a autocorrelação de cada edifício, comparando a série real normalizada com a sintética até 48 desfasamentos e calculando o erro médio absoluto entre as duas curvas, para verificar se a dependência temporal dos dados sintéticos se aproximava da observada nas séries reais.

3.8 Desenho experimental

3.8.1 Objetivo da avaliação

As experiências decorreram nos edifícios de avaliação. Compararam-se modelos treinados apenas com dados reais, modelos treinados com a fração real e o complemento sintético e, na previsão, modelos treinados com a fração real e ruído branco.

A comparação foi feita primeiro por edifício dentro de cada *split*. Posteriormente, verificou-se se a direção e a dimensão das diferenças entre cenários se repetiam quando mudava a composição dos grupos de edifícios.

A partir da semente de cada *split* foram definidas sementes próprias para a geração sintética, o ruído branco e a injeção de anomalias, permitindo reproduzir os valores gerados e os pontos alterados em novas execuções com a mesma semente.

3.8.2 Cenários experimentais

Na previsão do consumo, foi definido um cenário de referência com 100% dos dados reais disponíveis no período de treino. Além desse cenário, foram criados três cenários de escassez, usando apenas os primeiros 5%, 10% e 20% dos dados reais do período de treino. A utilização da parte inicial da série reproduz o caso de um edifício cuja monitorização começou recentemente [3]. O período de treino de cada edifício variou entre cerca de 491 e 512 dias, pelo que estas frações corresponderam aproximadamente a 25, 50 e 100 dias de histórico real.

Para cada nível de escassez foram criadas duas variantes: na primeira, os dados reais disponíveis foram complementados com dados sintéticos; na segunda, com ruído branco, como cenário de controlo.

Os valores de ruído foram criados nos mesmos *timestamps* usados pelo complemento sintético, garantindo que os cenários comparados tinham uma quantidade equivalente de observações acrescentadas ao treino.

No cenário sintético, os valores foram produzidos pelo gerador temporal calibrado nos edifícios de calibração. No cenário com ruído branco, os valores foram gerados de forma independente a partir de uma distribuição normal centrada na escala local de cada cenário, com desvio-padrão igual a 30% dessa escala. Quando surgiam valores negativos, estes eram colocados a zero, porque o consumo energético não pode assumir valores abaixo de zero. Os dois complementos diferiram apenas na forma como a variável de consumo acrescentada foi gerada. Em ambos, a temperatura associada a cada *timestamp* foi a temperatura real do *site*, pelo que o cenário de controlo manteve a estrutura temporal na temperatura; apenas o consumo acrescentado ficou sem essa estrutura.

Na deteção de anomalias foram avaliados os cenários com 100% real, 5% real, 10% real e 20% real. Também foram testadas as versões com dados sintéticos nos níveis de 5%, 10% e 20%. O cenário de controlo não foi executado nesta tarefa.

A amplitude do ruído foi fixada apenas para construir o cenário de controlo e não foi otimizada. O controlo verifica se a redução do erro também ocorre quando os valores de consumo acrescentados não têm estrutura temporal.

3.8.3 Coerência temporal dos cenários de escassez

Nos cenários de escassez foram usados os primeiros registos de cada edifício e não observações escolhidas aleatoriamente ao longo do treino. A janela inicial pode não conter ciclos presentes no período de teste.

Na previsão, estes cenários mantiveram pelo menos 24 observações reais. Os pontos reais foram preservados e os restantes instantes da janela de treino receberam valores sintéticos ou ruído branco. O complemento não aumentou apenas o número de observações: repôs a cobertura da janela de treino completa, incluindo horas, dias da semana e meses ausentes da fração inicial. Na deteção de anomalias, foram mantidas pelo menos 25 observações reais, o mínimo necessário para calcular a variável lag_{24} .

A Tabela 3 sintetiza os cenários experimentais.

Tabela 3: Síntese dos cenários experimentais

Tarefa	Cenário	Treino	Teste
Previsão	100% real (referência)	Todo o histórico real do período de treino	Real
Previsão	5% / 10% / 20% real	Primeiros 5%, 10% ou 20% do histórico real	Real
Previsão	5% / 10% / 20% real + sintético	Fração real e complemento sintético nos restantes <i>timesteps</i> do período de treino	Real
Previsão	5% / 10% / 20% real + ruído branco	Fração real e ruído branco nos mesmos <i>timesteps</i> do complemento sintético (controlo)	Real
Deteção de anomalias	100% real	Todo o histórico real do período de treino	Real, com anomalias artificiais injetadas
Deteção de anomalias	5% / 10% / 20% real	Primeiros 5%, 10% ou 20% do histórico real	Real, com anomalias artificiais injetadas
Deteção de anomalias	5% / 10% / 20% real + sintético	Fração real e complemento sintético	Real, com anomalias artificiais injetadas

3.9 Previsão do consumo

Na previsão do consumo foi usado o Prophet [5], cuja decomposição explícita em tendência e sazonalidades facilita a comparação dos cenários de treino, conforme discutido na Secção 2.2. O modelo foi treinado separadamente para cada edifício e cenário.

A variável prevista foi o consumo elétrico, com a temperatura exterior a entrar como regressor externo. Esta inclusão decorre da implementação utilizada e não da formulação apresentada no artigo original do Prophet. Não foram configurados feriados nem outros dias especiais.

Antes do ajuste, as séries de treino e teste passaram a frequência horária. As observações sem consumo foram removidas, sem imputação. As falhas de temperatura foram preenchidas por interpolação linear até seis horas e, nas restantes lacunas, pela média da temperatura do período de treino. A mesma média foi aplicada ao treino e ao teste para impedir que os valores do teste fossem usados na imputação.

O modelo usou as sazonalidades diária e semanal. A sazonalidade anual foi desativada porque as janelas de treino dos cenários de escassez eram demasiado curtas para representar um ciclo anual; a desativação manteve-se em todos os cenários, incluindo o de referência, para conservar a mesma configuração do Prophet.

3.10 Avaliação da previsão

A previsão foi avaliada através do RMSE, do erro absoluto médio (MAE) e da raiz do erro quadrático médio normalizado (NRMSE). O NRMSE foi definido como métrica principal, porque permite comparar edifícios com escalas de consumo diferentes.

Para cada edifício e cenário, as previsões foram comparadas com os valores reais do período de teste. O RMSE quantificou o erro, penalizando mais os desvios elevados. O MAE foi calculado como métrica auxiliar. O script calculou também o erro percentual absoluto médio (MAPE), mas esta métrica não integrou as comparações apresentadas no Capítulo 4. O NRMSE foi calculado dividindo o RMSE pela média do consumo real no período de treino completo do respetivo edifício e multiplicando por 100. O denominador é o mesmo em todos os cenários de um

edifício, o que torna os valores diretamente comparáveis entre cenários. Trata-se de uma normalização de avaliação, que não entra no treino dos modelos.

A previsão foi analisada primeiro por edifício e depois agregada por cenário e por *split*. Esta ordem permitiu identificar em que edifícios o erro diminuiu ou aumentou antes de calcular as médias.

Foram realizadas três comparações: treino apenas com histórico real escasso face ao treino com sintético; sintético face ao ruído branco; e cada cenário de escassez face ao cenário de referência com 100% do período de treino real.

3.11 Detecção de anomalias

3.11.1 Modelo utilizado

Na detecção de anomalias foi usado o Isolation Forest, um método não supervisionado adequado quando não existe uma identificação completa e fiável das anomalias [6, 24], conforme discutido na Secção 2.5. O modelo foi treinado separadamente para cada edifício e cenário.

O parâmetro `contamination` foi definido em 0,01. No scikit-learn, este parâmetro fixa o limiar de decisão a partir da distribuição das pontuações do conjunto de treino, e não a fração de pontos assinalados no teste: a proporção de alertas no período de teste depende das pontuações aí obtidas. O valor foi escolhido para acompanhar a proporção de anomalias injetadas no teste. Como o treino não contém anomalias artificiais, o limiar é calibrado sobre um conjunto assumido como isento de anomalias. Foi ainda fixado o parâmetro `random_state`, seguindo a lógica de sementes do restante *pipeline*. Os restantes parâmetros mantiveram os valores por defeito do scikit-learn, uma vez que a intenção não foi otimizar o modelo, mas comparar cenários de treino.

3.11.2 Construção das variáveis

No Isolation Forest foram usadas as variáveis consumo, hora do dia, dia da semana, consumo da observação anterior e consumo registado 24 observações antes. As duas últimas foram representadas por `lag_1` e `lag_24`, calculadas sobre a série ordenada por instante, e permitem relacionar o consumo atual com a hora anterior e com o mesmo horário do dia anterior sempre que a sequência é

contínua. Como a base resulta da remoção dos registos sem consumo ou sem temperatura, existem lacunas em que essa correspondência não se verifica.

O consumo, o `lag_1` e o `lag_24` foram normalizados com `StandardScaler`, ajustado apenas com os dados de treino e aplicado ao teste. A hora do dia e o dia da semana foram reescalados para o intervalo entre 0 e 1.

3.11.3 Injeção de anomalias artificiais

O *dataset* não disponibilizava uma identificação completa das anomalias reais que permitisse calcular *precision*, *recall* e F1-score. Foram, por essa razão, introduzidas perturbações artificiais apenas no período de teste.

Os pontos foram escolhidos aleatoriamente. A semente de cada edifício resultou da semente do *split* e da posição do edifício na ordem de processamento. Esta regra torna a seleção reprodutível e diferente entre edifícios, embora a faça depender dessa ordem.

O número de pontos alterados correspondeu a cerca de 1% do período de teste, com pelo menos uma anomalia por série. Mantendo os mesmos pontos injetados, o Isolation Forest foi treinado também com `contamination` igual a 0,008 e 0,012, ou seja, 20% abaixo e 20% acima do valor de referência. A análise verificou se a alteração do parâmetro modificava o F1-score e a ordenação entre os cenários apenas reais e os cenários com sintético.

Cada ponto seleccionado recebeu um aumento ou uma redução de três desvios-padrão. O desvio-padrão foi calculado no período de treino real completo do respetivo edifício. As reduções que originavam consumo negativo foram truncadas para zero.

A identificação dos pontos alterados foi guardada apenas para avaliar as classificações produzidas pelo Isolation Forest e não entrou no treino. As primeiras observações sem histórico suficiente para calcular `lag_1` e `lag_24` foram removidas antes do cálculo das métricas.

3.11.4 Métricas de avaliação

Na deteção de anomalias foram usadas as métricas *precision*, *recall* e F1-score.

A *precision* correspondeu à proporção dos pontos assinalados como anómalos pelo modelo que eram anomalias injetadas. O *recall* correspondeu à proporção

das anomalias introduzidas no teste que o modelo identificou. O F1-score foi definido como métrica principal, por combinar *precision* e *recall*.

Mesmo assim, a *precision* e o *recall* foram analisados separadamente, para determinar se uma quebra de desempenho resultava de excesso de falsos alertas ou da perda de capacidade para identificar as anomalias introduzidas no teste.

3.12 Múltiplos *splits* e estabilidade dos resultados

As experiências foram repetidas em cinco *splits*, com as sementes 42, 100, 200, 400 e 500. Em cada um, a cadeia principal do *pipeline* foi executada de novo, da seleção dos edifícios à deteção de anomalias.

A repetição permitiu avaliar quanto os resultados mudavam com a seleção dos edifícios. Diferenças acentuadas entre *splits* indicariam forte dependência da composição dos grupos; a repetição da mesma direção entre cenários indicaria que a conclusão não dependia de uma única repartição.

Depois das execuções, foram reunidos os resultados da previsão, da deteção de anomalias e da análise por edifício. Antes de produzir os resumos finais, um script confirmou que os três ficheiros consolidados continham as sementes 42, 100, 200, 400 e 500.

Nas tabelas finais, a média e o desvio-padrão de cada métrica foram calculados entre os cinco valores já agregados por *split*. O símbolo « $\pm$ » representa, por isso, a variação entre *splits* e não a dispersão entre edifícios.

3.13 Análise estatística

A análise estatística formal foi aplicada à tarefa de previsão, com o NRMSE como métrica principal na comparação entre cenários.

Foram comparados os cenários com poucos dados reais e os cenários com dados reais complementados por dados sintéticos, nos níveis de 5%, 10% e 20%. Também se compararam os dois cenários, um com ruído branco e outro com dados sintéticos, para determinar se o sintético apresentava vantagem face ao controlo.

A normalidade das diferenças foi avaliada com o teste de Shapiro-Wilk [29] e registada por *split*. O resultado não condicionou a escolha do procedimento: dada a

dimensão reduzida das amostras por *split*, a comparação entre cenários recorreu sempre ao teste de Wilcoxon.

O teste de Wilcoxon [30] é adequado a resultados emparelhados quando não se pretende assumir normalidade das diferenças. Em cada *split*, os mesmos edifícios de avaliação foram usados em todos os cenários, o que permitiu comparar diretamente os respetivos erros.

Como cada *split* incluía apenas cinco edifícios de avaliação, os testes individuais tinham poder estatístico limitado. Com cinco pares, o menor p-valor que o teste de Wilcoxon bilateral pode produzir é 0,0625, acima do nível de 0,05. O mesmo número de pares restringe o p-valor a oito valores possíveis, entre 0,0625 e 1, pelo que a repetição de valores entre *splits* na Tabela 15 decorre da dimensão da amostra.

Os p-valores dos diferentes *splits* foram, por isso, combinados pelo método de Fisher, para agregar a evidência estatística das cinco execuções. Os *splits* são quase disjuntos: as 60 seleções das cinco execuções correspondem a 55 edifícios distintos. Nos conjuntos de avaliação, as 25 seleções correspondem a 23 edifícios distintos, porque dois edifícios aparecem em dois *splits*. Ainda assim, os edifícios provêm do mesmo conjunto finito de edifícios de educação do BDG2 e partilham *sites* e séries meteorológicas, pelo que os p-valores não são totalmente independentes, condição assumida pelo método de Fisher [31]. O p-valor combinado foi usado apenas para resumir os cinco testes e não como prova de que o resultado se generaliza a todos os edifícios de educação.

Para além do p-valor, foi calculado $r = |z|/\sqrt{n}$ a partir da estatística padronizada do teste de Wilcoxon, com n igual ao número de pares [32]. Com cinco edifícios, este indicador mostra sobretudo se as cinco diferenças dentro de um *split* apontam no mesmo sentido. Não indica a dimensão da redução do NRMSE e, por ser calculado em valor absoluto, não identifica qual cenário obteve menor erro. Quando as cinco diferenças têm o mesmo sinal, r atinge o valor máximo de aproximadamente 0,90. Com cinco pares, também r fica restrito a oito valores. A média entre *splits* pode ainda reunir execuções com direções opostas. Os limiares de 0,3 e 0,5 foram usados apenas como classificação convencional [33].

A magnitude do efeito na previsão foi ainda descrita por um procedimento de *bootstrap* [34], aplicado à comparação entre 20% de dados reais e 20% de dados reais complementados com sintético. Em cada *split* foi calculado o ganho medi-

ano de NRMSE entre os cinco edifícios de avaliação. As cinco medianas foram reamostradas com reposição, com semente fixa, ao longo de 5 000 iterações, tomando-se a média de cada reamostra. O intervalo de confiança a 95% corresponde aos percentis 2,5 e 97,5 dessa distribuição e refere-se, por isso, à média dos ganhos medianos por *split*, e não ao ganho de um edifício individual. A unidade de reamostragem é o *split*, o que evita tratar edifícios do mesmo *split* como observações independentes, mas limita a precisão do intervalo, dado existirem apenas cinco unidades.

Na previsão, o erro é uma variável contínua diretamente comparável entre cenários, pelo que os testes estatísticos compararam os valores de NRMSE dos mesmos edifícios entre cenários. Na deteção de anomalias, a análise considerou em conjunto a *precision*, o *recall* e o F1-score e verificou se a direção das diferenças se repetia nos cinco *splits*.

3.14 Ferramentas e bibliotecas utilizadas

O *pipeline* foi desenvolvido em Python e organizado em scripts sequenciais.

A Tabela 4 lista as bibliotecas e os módulos usados no *pipeline*.

Tabela 4: Bibliotecas e módulos usados no *pipeline*

Biblioteca ou módulo	Utilização no <i>pipeline</i>
Python	Execução do <i>pipeline</i> e coordenação dos scripts
pandas	Leitura dos ficheiros, limpeza, transformação das tabelas e junção entre consumo e meteorologia
numpy	Cálculos numéricos, controlo de sementes e geração do ruído sintético
matplotlib	Geração das figuras da análise exploratória, validação e resultados
seaborn	Apoio à construção de gráficos exploratórios e comparativos
Prophet	Modelo de previsão do consumo energético
scikit-learn	Isolation Forest, <code>StandardScaler</code> e métricas de avaliação
scipy	Testes Kolmogorov-Smirnov, Shapiro-Wilk, Wilcoxon e combinação pelo método de Fisher
statsmodels	Cálculo da função de autocorrelação na validação temporal das séries sintéticas
os, sys, time, subprocess e shutil	Gestão de caminhos, execução dos scripts, repetição dos <i>splits</i> e organização dos ficheiros gerados

As configurações completas do Prophet e do Isolation Forest encontram-se no Apêndice B.

3.15 Delimitações metodológicas

Na implementação foi usada a temperatura exterior observada no *dataset* ao longo de todo o período das séries, tanto no treino como no teste, incluindo os instantes do período de treino cujo consumo real foi assumido como indisponível. O *pipeline* não produziu previsões meteorológicas. No período de teste, o Prophet recebeu como regressor a temperatura que veio a registar-se, e não a que estaria disponível no momento em que a previsão seria feita. Esta opção torna os cenários de escassez menos exigentes do que seriam se, no período de teste, fossem usadas previsões meteorológicas ou se a temperatura estivesse igualmente limitada.

O gerador sintético não corresponde a uma simulação física dos edifícios, mas à reprodução de padrões estatísticos observados no consumo e na temperatura.

A informação meteorológica estava associada ao *site* e não a cada edifício, pelo que edifícios do mesmo *site* partilharam a mesma temperatura exterior. A opção é coerente com a estrutura do *dataset*, mas limita a representação de diferenças microclimáticas.

O cenário de controlo com ruído branco introduz, na variável de consumo acrescentada, valores aleatórios, mas a sua amplitude foi fixada em 30% da escala local e não foi ajustada à dispersão do complemento sintético. A comparação entre os dois complementos reflete, assim, diferenças de estrutura e, em parte, de amplitude.

O controlo foi aplicado apenas à previsão. Esta assimetria limita a interpretação dos resultados e impede afirmar, na deteção de anomalias, se a degradação observada resulta da estrutura das séries geradas, da sua dispersão ou da extensão da janela de treino com mais observações.

A restrição à tipologia de educação impede a generalização direta para outras tipologias.

Na deteção de anomalias, a avaliação recorreu a anomalias artificiais introduzidas no período de teste. Este procedimento permitiu controlar a localização e a

intensidade das perturbações, mas não substitui uma validação com anomalias reais previamente identificadas.

Como os desfasamentos de 1 e 24 observações foram calculados depois da injeção, uma perturbação num ponto alterou também as variáveis de entrada das observações nas posições $t + 1$ e $t + 24$ da série ordenada. Apenas o ponto originalmente modificado foi assinalado como anómalo. Esta condição foi igual em todos os cenários e não invalida a comparação relativa, mas pode reduzir os valores absolutos de *precision* e F1-score.

Por fim, cada modelo manteve a mesma configuração nas comparações principais, sem otimização exaustiva de hiperparâmetros, uma vez que o objetivo foi comparar cenários de treino e não obter o melhor desempenho absoluto.

3.16 Síntese da metodologia

A metodologia avaliou o efeito dos dados sintéticos em cenários com pouco histórico real. O gerador combinou um perfil horário e semanal, um ajuste pela temperatura exterior e uma componente residual AR(1). Os parâmetros foram estimados nos edifícios de calibração e aplicados aos edifícios de avaliação, cujo consumo não entrou na calibração. As séries geradas complementaram apenas o treino; o teste permaneceu sempre real.

Na previsão, o Prophet foi avaliado através do NRMSE nos cenários com 5%, 10% e 20% de histórico real, com ruído branco como controlo. Na deteção de anomalias, o Isolation Forest foi avaliado através de *precision*, *recall* e F1-score sobre perturbações introduzidas no teste. As experiências foram repetidas em cinco *splits*. A previsão incluiu testes estatísticos e a deteção foi comparada descritivamente entre cenários e *splits*. O capítulo seguinte apresenta a validação do gerador e os resultados nas duas tarefas.

4. Resultados

4.1 Introdução ao capítulo

Este capítulo apresenta a validação do gerador e mede como o complemento sintético alterou o erro de previsão e as métricas de detecção de anomalias nos cenários com pouco histórico real. A análise verifica em que cenários o complemento reduziu o NRMSE, se apresentou vantagem face ao ruído branco e como alterou a *precision*, o *recall* e o F1-score do Isolation Forest.

As duas tarefas são analisadas em separado. O Prophet usa os dados de treino para estimar a tendência e as sazonalidades do consumo. O Isolation Forest usa-os para definir os valores e as combinações de variáveis que considera normais. Em todas as experiências, os modelos foram avaliados no período de teste real e os dados sintéticos entraram apenas no treino.

A validação do gerador antecede a análise dos modelos porque duas séries com médias próximas podem diferir na dispersão, nos valores superiores, na distribuição e na dependência entre observações consecutivas.

4.2 Validação dos dados sintéticos

4.2.1 Comportamento do gerador sintético

A validação começou com a comparação entre as séries reais e sintéticas antes da sua utilização nos modelos. O objetivo não era reconstruir o consumo real hora a hora, mas verificar se as séries geradas mantinham o nível médio, o perfil horário e semanal e alguma dependência entre observações consecutivas.

Esta validação foi realizada sobre os edifícios de avaliação de um único *split*, correspondente à semente 500. Por esse motivo, os resultados desta subsecção caracterizam o comportamento do gerador nesse conjunto de edifícios. O impacto dos dados sintéticos nos modelos foi analisado posteriormente nos cinco *splits*.

A média normalizada dos dados reais foi de 1,000 por definição, porque cada série foi dividida pela própria média do período de treino. A comparação relevante é a média sintética de 0,998, que ficou 0,22% abaixo desse valor.

A principal diferença surgiu na dispersão. O desvio-padrão normalizado aumentou de 0,328 nos dados reais para 0,488 nos dados sintéticos, e o percentil 99 passou de 1,705 para 2,415. A média manteve-se próxima de 1,000, mas os valores sintéticos ficaram mais dispersos e incluíram consumos superiores aos observados com a mesma frequência nos dados reais.

Na calibração do *split* 500, o coeficiente térmico estimado foi de cerca de $-0,002$. Uma amplitude de dez graus corresponde, com este coeficiente, a uma variação de cerca de 2% no consumo normalizado, contra um desvio-padrão sintético de 0,488. Com este valor, a variação do consumo sintético resultou principalmente do perfil horário e semanal e da componente residual AR(1).

O RMSE normalizado do gerador foi de 0,479, o que mostra que os valores sintéticos não reproduzem os valores reais em cada instante. Este valor excede o desvio-padrão real de 0,328, ou seja, o erro em cada hora é superior ao que resultaria de prever a média constante da série. Esta diferença é compatível com a função atribuída às séries sintéticas, que complementam o treino e não substituem o consumo real.

A estatística média do teste de Kolmogorov-Smirnov foi de 0,199 e a hipótese de igualdade das distribuições foi rejeitada nos cinco edifícios. As séries sintéticas não reproduziram, portanto, a distribuição das séries reais.

A autocorrelação foi analisada até 48 defasamentos. O erro médio absoluto entre a função de autocorrelação (ACF) real e a sintética foi de 0,229. O gerador introduziu dependência entre observações consecutivas, mas a autocorrelação sintética não coincidiu com a real ao longo dos 48 defasamentos.

As métricas agregadas foram calculadas no período de treino do *split* 500, porque as séries sintéticas foram usadas apenas para complementar o treino. As figuras seguintes são ilustrativas e abrangem também o período de teste, permitindo comparar as séries reais e sintéticas na mesma escala normalizada durante todo o período analisado.

A Tabela 5 reúne as métricas usadas na validação do gerador sintético.

Tabela 5: Métricas de validação do gerador sintético

Métrica	Dados reais	Dados sintéticos	Diferença (%)
Média normalizada	1,000 (por construção)	0,998	0,22%
Desvio-padrão normalizado	0,328	0,488	48,76%
Percentil 99 normalizado	1,705	2,415	41,68%
RMSE normalizado do gerador	—	0,479	—
Estatística KS média	—	0,199	—
Taxa de rejeição KS	—	100%	—
MAE médio da ACF até 48 desfasamentos	—	0,229	—

Nota: cada métrica corresponde à média, entre os cinco edifícios de avaliação do *split* 500, da estatística calculada individualmente em cada série. Não são estatísticas da distribuição agregada de todas as observações: o desvio-padrão e o percentil 99 calculados sobre o conjunto reunido seriam superiores, por incorporarem a variação entre edifícios. As três primeiras linhas comparam séries reais e sintéticas; as restantes descrevem a relação entre as duas séries.

4.2.2 Distribuições, ritmos semanais e detalhe temporal

A curva real corresponde ao consumo elétrico horário observado nos edifícios de educação selecionados do BDG2, normalizado no *pipeline*, e não a dados simulados ou reconstruídos.

As Figuras 5 e 6 comparam as distribuições dos consumos reais e sintéticos na mesma escala normalizada. A curva sintética corresponde a uma nova série gerada pelo modelo e não à transformação da curva real.

Na Figura 5, o eixo vertical representa a densidade estatística e não o consumo médio. O pico mais baixo da curva sintética não significa, por isso, que o consumo sintético seja inferior ao real. Indica apenas que há menos observações sintéticas concentradas no intervalo mais frequente dos dados reais, entre 0,5 e 1,0. A curva sintética distribui-se por um intervalo mais amplo de consumos baixos e elevados, confirmando a maior dispersão indicada pelo desvio-padrão.




Figura 5: Distribuição de densidade dos consumos reais e sintéticos normalizados na zona central.

Na Figura 6, a distribuição sintética prolonga-se mais para a direita e contém uma proporção superior de consumos elevados. Esta diferença corresponde ao maior desvio-padrão e ao maior percentil 99 apresentados na Tabela 5.




Figura 6: Distribuição de densidade dos consumos reais e sintéticos normalizados com maior detalhe da cauda superior.

Na Figura 7, o consumo real é mais elevado nos dias úteis, sobretudo entre as

8h e as 17h, com maior intensidade entre o final da manhã e o meio da tarde. Ao fim de semana, o consumo diminui, o que corresponde aos horários habituais dos edifícios de educação.

O perfil sintético, ilustrado no gráfico B, mantém a separação entre os dias úteis e o fim de semana. Também reproduz a maior concentração de consumo durante o período diurno, embora a intensidade não coincida totalmente com a dos dados reais. As Figuras 5 e 6 reúnem todos os valores numa distribuição, enquanto a Figura 7 calcula uma média separada para cada hora e dia da semana.

O gráfico C mostra a diferença direta entre os dois perfis, real e sintético, calculada como consumo real menos consumo sintético. As zonas avermelhadas correspondem aos períodos em que o consumo real ficou acima do sintético, enquanto as zonas azuladas representam o contrário. O gráfico mantém a unidade normalizada dos gráficos A e B, mas usa uma escala cromática própria, centrada na diferença entre os dois perfis.

Uma cor mais intensa no gráfico C não significa que o consumo nesse período seja elevado. Significa apenas que a diferença entre o real e o sintético é das maiores dentro do painel de diferenças. Por esse motivo, alguns blocos de sábado e domingo podem surgir com cores fortes, mesmo quando os valores absolutos dos gráficos A e B são mais baixos.

As diferenças são mais visíveis ao fim de semana, no sábado e no domingo entre as 8h e as 14h, quando o consumo real é superior ao sintético. Entre sexta-feira e domingo, o padrão inverte-se entre as 17h e as 23h, em especial ao domingo, período em que o sintético fica acima do real. Durante a madrugada, entre as 0h e as 3h, também surgem diferenças, porém de menor intensidade.

Nos dias úteis, as maiores diferenças ocorrem ao final do dia, entre as 22h e as 23h, e no final da manhã, entre as 10h e as 12h, períodos em que o perfil sintético se mantém acima do real. Às 7h, na transição da manhã, o sentido inverte-se e o consumo real supera o sintético. O perfil sintético reproduziu a diferença entre dias úteis e fim de semana, mas não reproduziu a intensidade do consumo real em todos os blocos horários.




Figura 7: Perfil horário e semanal médio do consumo real (A), do consumo sintético (B) e da diferença direta entre ambos (C), com $C = \text{real} - \text{sintético}$.

A Figura 8 passa da análise agregada das Figuras 5 e 6 e do perfil médio da Figura 7 para uma janela temporal de dois edifícios. Os edifícios foram escolhidos entre os cinco edifícios de avaliação do *split* 500 com base no coeficiente de variação do consumo real. O gráfico A apresenta o menor CV, 0,192, e o gráfico B o maior, 0,496. As linhas claras representam os valores horários e as linhas espessas a média móvel de 24 horas, que reduz as oscilações entre horas consecutivas.

A série sintética não constitui uma reconstrução ponto a ponto da série real. A distância entre as linhas representa a diferença entre duas séries produzidas separadamente e não um erro de previsão hora a hora.

No edifício Robin_Megan, representado no gráfico A, o consumo real apresenta menor variação e permanece próximo da média durante a janela mostrada. A média móvel sintética mantém um nível semelhante, mas apresenta oscilações mais amplas entre 29 e 31 de dezembro e entre 3 e 5 de janeiro.

No edifício Wolf_Laurinda, representado no gráfico B, o consumo real apresenta subidas e descidas acentuadas entre 2 e 4 de janeiro. A série sintética varia de forma mais suave e não reproduz essas alterações com a mesma amplitude.

A normalização coloca as séries na mesma escala de comparação, mas não as obriga a ter a mesma variância, pelo que os dados sintéticos podem apresentar maior dispersão mesmo depois de normalizados.

Comparação entre séries reais e sintéticas em edifícios com menor e maior coeficiente de variação




Figura 8: Séries reais e sintéticas normalizadas de dois edifícios selecionados pelo menor e maior **coeficiente de variação** do consumo real.

4.3 Efeito dos dados sintéticos na previsão do consumo

4.3.1 Impacto da escassez de dados reais no erro de previsão

O cenário de referência, treinado com 100% do período de treino real, obteve RMSE médio de 51,053 e NRMSE médio de 31,234%.

Quando o treino foi reduzido à parte inicial da série, o NRMSE médio aumentou para 284,402% com 5% de histórico, 344,454% com 10% e 154,494% com 20%. Os três cenários apresentaram, portanto, erro superior ao cenário de referência.

O NRMSE médio do cenário de 10% foi superior ao do cenário de 5%, pelo que o erro não diminuiu sempre com o aumento do histórico. Este resultado é compatível com a sensibilidade do Prophet ao conteúdo das janelas cronológicas curtas: a janela de 10% pode incluir padrões que não representam o período de teste. O desenho experimental não isolou, contudo, quais padrões produziram esta diferença.

Com o complemento sintético, o NRMSE médio desceu para 34,970%, 35,324% e 34,702% nos cenários de 5%, 10% e 20%, respetivamente. Estes valores ficaram entre 3,468 e 4,090 pontos percentuais acima do cenário de referência.

O ruído branco produziu NRMSE médio de 35,905%, 35,383% e 34,248% nos mesmos três níveis. Os valores do ruído e do sintético situaram-se, assim, entre 34% e 36%.

Como os valores do ruído e do sintético ficaram próximos, a melhoria não pode ser atribuída apenas à estrutura do gerador. Os dois complementos ocupam os mesmos instantes do período de treino e repõem, ambos, a extensão temporal da janela que a fração real escassa não cobre. Parte do ganho pode resultar da reposição da janela de treino com mais observações, e não da estrutura das séries geradas.

A Tabela 6 apresenta os resultados obtidos na previsão.

Tabela 6: Resultados da previsão por cenário

Cenário	RMSE médio $\pm$ desvio	NRMSE médio (%) $\pm$ desvio
100% real	51,053 $\pm$ 35,860	31,234 $\pm$ 11,257
5% real	593,109 $\pm$ 392,763	284,402 $\pm$ 100,240
5% real + ruído	68,187 $\pm$ 57,095	35,905 $\pm$ 4,855
5% real + sintético	72,295 $\pm$ 54,378	34,970 $\pm$ 4,249
10% real	698,646 $\pm$ 709,569	344,454 $\pm$ 244,507
10% real + ruído	65,989 $\pm$ 54,421	35,383 $\pm$ 5,515
10% real + sintético	72,008 $\pm$ 54,100	35,324 $\pm$ 4,404
20% real	235,507 $\pm$ 193,477	154,494 $\pm$ 103,674
20% real + ruído	62,940 $\pm$ 51,370	34,248 $\pm$ 6,994
20% real + sintético	68,496 $\pm$ 50,589	34,702 $\pm$ 5,682

Nota: cada valor corresponde à média, entre os cinco *splits*, do erro médio por edifício, seguida do desvio-padrão entre *splits*. O desvio-padrão descreve a variação dos resultados entre repartições da amostra e não a variação entre edifícios.

A Figura 9 apresenta o NRMSE do Prophet em cada cenário de treino. A linha de 100% real representa o erro do modelo treinado com todo o período de treino real e não um erro dos dados.

No gráfico A, os cenários apenas reais apresentam NRMSE entre 154,494% e 344,454%, enquanto a referência apresenta 31,234%.

O gráfico B amplia os cenários com complemento, cujos valores se situam entre 34% e 36%.




Figura 9: Erro de previsão do Prophet por cenário de treino, medido através do NRMSE.

A Figura 10 apresenta a mesma comparação em RMSE. Os cenários apenas reais obtiveram RMSE médio entre 235,507 e 698,646, enquanto os cenários com complemento ficaram entre 62,940 e 72,295.

O controlo apresentou RMSE inferior ao sintético nos três níveis. A diferença foi de 4,108 no cenário de 5%, 6,019 no de 10% e 5,556 no de 20%. O RMSE é apresentado como medida complementar porque é expresso em kWh e varia com a escala de consumo dos edifícios.




Figura 10: Erro de previsão do Prophet por cenário de treino, medido através do RMSE.

4.3.2 Consistência dos resultados entre *splits*

A *pipeline* foi repetido em cinco *splits*, como descrito na Secção 3.12, para verificar se o NRMSE diminuía com o sintético em diferentes grupos de edifícios e quanto variava a dimensão dessa redução.

Os resultados completos por *split* são apresentados na Tabela 13, no Apêndice C.

Nos cenários apenas reais, o desvio-padrão do NRMSE entre *splits* foi de 100,240 com 5% de histórico, 244,507 com 10% e 103,674 com 20%. A maior variação ocorreu, portanto, no cenário de 10%.

Nos cenários com dados sintéticos, o NRMSE médio variou entre 29,094% e 39,800% no cenário de 5% real + sintético, entre 29,136% e 39,057% no cenário de 10% real + sintético, e entre 28,313% e 41,384% no cenário de 20% real + sintético.

Estes valores ficaram próximos do NRMSE médio de 31,234% do cenário de referência e, nos cinco *splits*, abaixo dos valores obtidos nos cenários apenas reais.

A redução do erro ocorreu nos cinco *splits*, mas a sua dimensão variou entre os grupos de edifícios. A secção seguinte apresenta essa variação por edifício.

4.4 Variação dos resultados entre edifícios

4.4.1 Diferenças no efeito dos dados sintéticos por edifício

A análise por edifício incidiu no cenário de 20%, o nível de escassez que continha a maior fração de histórico real sem usar o período de treino completo.

Nos 25 casos edifício-*split*, o NRMSE diminuiu em 22 e não diminuiu em 3. A dimensão da redução variou entre edifícios, desde valores próximos de zero até 94,1%.

Os edifícios com NRMSE inicial baixo apresentavam uma diferença menor entre o erro inicial e zero, enquanto os edifícios com erro inicial elevado permitiam reduções absolutas maiores. Esta relação é apenas descritiva e não demonstra que o erro inicial seja a causa da diferença entre ganhos.

A variação aparece em edifícios de *splits* diferentes, uma vez que esta análise reúne os 25 casos edifício-*split* dos cinco *splits*. Com ganhos em NRMSE acima de 89%, surgem os edifícios Bear_Gavin, Lamb_Williams, Peacock_Lyle e Hog_Bruno. No sentido oposto, o complemento sintético agravou o erro em Rat_Deبرا e Moose_Marina, e o ganho foi praticamente nulo em Robin_Megan. O edifício Peacock_Ophelia surge em dois *splits* e muda de sinal entre eles, com ganho ligeiramente negativo num e ligeiramente positivo no outro. A repetição do mesmo edifício em mais de um *split* deve, por isso, ser considerada na leitura dos resultados agregados.

Na Figura 11, cada linha representa um *split* de edifícios e cada ponto corresponde ao NRMSE mediano dos cinco edifícios de avaliação desse *split*. O ponto azul representa o cenário treinado apenas com 20% de dados reais, enquanto o ponto laranja representa o mesmo cenário depois da inclusão dos dados sintéticos. O segmento entre os dois pontos mostra a descida do NRMSE mediano. O valor percentual anotado junto a cada segmento corresponde a uma grandeza

diferente: é a mediana dos ganhos relativos calculados edifício a edifício dentro desse *split*, e não a variação entre os dois pontos representados. A caixa de resumo apresenta o intervalo *bootstrap* imediatamente abaixo do ganho mediano, mas o intervalo refere-se à média dos ganhos medianos por *split*, como se detalha na Secção 4.4.2.

O NRMSE mediano diminuiu nos cinco *splits*. A mediana dos ganhos por edifício foi de 16,1% no *split* 100 e situou-se entre 63,1% e 81,1% nos restantes.




Figura 11: Comparação do NRMSE mediano entre os cenários 20% real e 20% real + sintético.

A Figura 12 apresenta os ganhos percentuais em NRMSE por edifício e por *split*. O *split* 100 incluiu ganhos positivos e negativos. Nos *splits* 42 e 400 surgiu também um valor negativo em cada um. Nos *splits* 200 e 500, os cinco edifícios apresentaram ganhos positivos, a maioria acima de 50%.




Figura 12: Distribuição dos ganhos percentuais em NRMSE por edifício e por *split* no cenário de 20%.

4.4.2 Síntese quantitativa dos ganhos no cenário de 20%

A síntese dos ganhos partiu da comparação entre o cenário 20% real e o cenário 20% real + sintético. Em cada edifício, foi calculada a variação percentual do NRMSE entre os dois cenários. Em seguida, dentro de cada *split*, os resultados foram resumidos pela mediana, para reduzir o peso dos casos extremos.

Os ganhos por edifício no cenário de 20% são apresentados na Tabela 14.

A mediana das cinco medianas de ganhos por *split* foi de 65,68% e a média foi de 58,67%. O intervalo *bootstrap* de 95% [34] para essa média foi de 36,26% a 74,43%. A reamostragem incidiu apenas sobre cinco valores, pelo que o intervalo descreve a variação obtida ao reamostrar as cinco medianas de *split*; não representa a incerteza ao nível dos 25 casos edifício-*split* nem permite generalizar para todos os edifícios de educação. O intervalo manteve-se, ainda assim, acima de zero.

Em cada *split*, pelo menos quatro dos cinco edifícios reduziram o NRMSE. No conjunto das execuções, a redução ocorreu em 22 dos 25 casos edifício-*split*, correspondentes a 88%.

A Tabela 7 apresenta a síntese dos ganhos no cenário de 20% de dados reais.

Tabela 7: Síntese dos ganhos no cenário de 20%

Indicador	Valor
<i>Splits</i> analisados	5
Casos edifício- <i>split</i> analisados	25
Mediana dos ganhos medianos por <i>split</i>	65,68%
Média dos ganhos medianos por <i>split</i>	58,67%
Intervalo <i>bootstrap</i> de 95% para a média dos ganhos medianos	36,26% a 74,43%
<i>Splits</i> com melhoria maioritária	100%
Média de edifícios com melhoria	88%

A Figura 13 apresenta o RMSE mediano em kWh, enquanto a Figura 12 apresenta ganhos percentuais em NRMSE por edifício. Como as métricas usam escalas diferentes, a ordenação dos *splits* não tem de coincidir.

O *split* 100 apresentou o menor ganho mediano em NRMSE, mas não apresentou o maior RMSE mediano. Foi o único *split* em que o RMSE mediano aumentou com o complemento sintético.

Nos *splits* 42, 200, 400 e 500, o RMSE mediano diminuiu. A maior redução em kWh ocorreu no *split* 42, enquanto a maior redução relativa ocorreu no *split* 400.




Figura 13: Comparação do RMSE mediano por *split* no cenário de 20% de dados reais.

4.5 Análise estatística dos resultados da previsão

4.5.1 Comparação entre dados reais escassos e dados reais com sintético

A análise estatística foi realizada com base no NRMSE, por ser a métrica de referência na avaliação da previsão. Em cada *split*, os edifícios foram comparados em dois cenários: treino apenas com uma fração reduzida de dados reais e treino com a mesma fração de dados reais complementada com dados sintéticos.

A comparação foi feita com o teste emparelhado de Wilcoxon em cada *split*. Os cinco *p*-valores de cada nível de escassez foram depois combinados pelo método de Fisher, produzindo um *p*-valor combinado para 5%, outro para 10% e outro para 20%.

Nos três níveis de escassez, o cenário com dados sintéticos apresentou NRMSE inferior ao cenário treinado apenas com dados reais. Com 5% de dados reais, o *p*-valor combinado pelo método de Fisher foi de 0,0117. No cenário de 10%, o valor desceu para 0,0020 e, no cenário de 20%, voltou a situar-se em 0,0117. Os três valores ficaram abaixo de 0,05.

Como se descreveu na Secção 3.13, os cinco *splits* partilham alguns edifícios, pelo que os *p*-valores não são totalmente independentes, condição assumida pelo método de Fisher. Os valores combinados resumem os cinco testes, mas não devem ser interpretados como demonstração de generalização a outros edifícios.

Nenhum teste individual de Wilcoxon, apresentado com detalhe na Tabela 15, ficou abaixo de 0,05. Com cinco pares, o menor *p*-valor bilateral possível é 0,0625; os resultados individuais não poderiam, portanto, atingir o limiar de 0,05.

O indicador r médio foi de 0,8080 nos cenários de 5% e 20%, e de 0,9045 no cenário de 10%. O valor máximo de 0,9045 foi atingido nos cinco *splits* do cenário de 10% e em dois dos cinco *splits* nos cenários de 5% e 20%. Nos restantes *splits*, o efeito continuou classificado como forte, mas não correspondeu a diferenças unânimes no mesmo sentido.

Estes valores não devem ser lidos como medida da dimensão do ganho: com cinco pares, r satura em 0,9045 quando todas as diferenças apontam no mesmo sentido, e o indicador não tem sinal. A magnitude do efeito é dada pelo NRMSE e pelo intervalo *bootstrap* da Secção 4.4.2, não por r .

4.5.2 Comparação entre dados sintéticos e ruído branco

A comparação seguinte testou se o NRMSE diferia entre o complemento sintético e o ruído branco. Nos dois tipos de complemento, o NRMSE médio ficou entre 34% e 36%, abaixo dos cenários apenas reais.

Nos três níveis de escassez, os p -valores combinados pelo método de Fisher situaram-se acima de 0,05. No cenário de 5%, o p -valor foi de 0,4260; no de 10%, de 0,3430; e no de 20%, de 0,4389. Estes resultados indicam que os testes não sustentaram uma diferença estatisticamente significativa entre o treino com dados sintéticos e o treino de controlo.

Os valores médios de r foram moderados: 0,4462 no cenário de 5%, 0,4703 no de 10% e 0,4462 no de 20%. Estes valores não indicam direção, porque r não tem sinal, e resultam da agregação de *splits* que apontam em sentidos opostos: em cada nível, três *splits* favorecem o controlo e dois favorecem o sintético. A direção média, obtida a partir da diferença relativa de NRMSE por edifício, favorece ligeiramente o controlo. A ausência de significância não demonstra equivalência entre os dois complementos, mas impede concluir que o sintético tenha sido superior ao ruído branco nestas condições.

As medidas agregadas não produziram a mesma ordenação entre os complementos. A mediana do NRMSE favoreceu o sintético nos três níveis. A média global favoreceu o sintético em 5% e 10% e o ruído em 20%. A média das diferenças relativas por edifício favoreceu o ruído nos três níveis.


Nestas condições, não ficou demonstrado que o complemento sintético fosse estatisticamente superior ao ruído branco. A leitura desta comparação é retomada na Secção 4.7.

A Tabela 8 reúne as duas comparações estatísticas da previsão. As três primeiras linhas apresentam o contraste entre o treino com poucos dados reais e o treino complementado com dados sintéticos. As três últimas linhas apresentam a comparação entre o controlo e os dados sintéticos.

Tabela 8: Testes estatísticos da previsão com base no NRMSE

Comparação	p de Fisher	Significativo a 0,05	r médio	Classificação convencional
5% real vs. 5% real + sintético	0,0117	Sim	0,8080	Forte
10% real vs. 10% real + sintético	0,0020	Sim	0,9045	Forte
20% real vs. 20% real + sintético	0,0117	Sim	0,8080	Forte
5% real + ruído vs. 5% real + sintético	0,4260	Não	0,4462	Moderado
10% real + ruído vs. 10% real + sintético	0,3430	Não	0,4703	Moderado
20% real + ruído vs. 20% real + sintético	0,4389	Não	0,4462	Moderado

A Figura 14 apresenta os p -valores combinados pelo método de Fisher. No gráfico A, relativo à comparação entre treino real escasso e treino real com complemento sintético, os três pontos ficam abaixo do limiar de 0,05. No gráfico B, relativo à comparação entre dados sintéticos e o controlo, os três pontos ficam acima desse limiar.


Figura 14: p -valores combinados pelo método de Fisher nas comparações da previsão.

A Figura 15 detalha os p -valores do teste de Wilcoxon em cada *split*. Ao contrário da Figura 14, que apresenta o resultado combinado pelo método de Fisher, esta figura mostra os testes individuais realizados em cada repartição de edifícios.

Na comparação entre treino real escasso e treino real com sintético, os p -valores ficam próximos do limiar de 0,05, em especial no cenário de 10%, em que os cinco *splits* registaram o mesmo valor, 0,0625. Nos restantes cenários, observa-se maior variação entre *splits*.

Na comparação entre o controlo e o sintético, os p -valores aparecem mais dispersos e, na maioria dos casos, acima de 0,05.




Figura 15: Distribuição dos p -valores de Wilcoxon por *split*.

4.6 Resultados da deteção de anomalias

4.6.1 Comparação entre cenários

Na previsão, o complemento sintético reduziu o NRMSE; na deteção de anomalias, reduziu o F1-score nos três níveis de escassez. A Tabela 16 apresenta a *precision*, o *recall* e o F1-score por cenário e por *split*.

O cenário de referência obteve F1 médio de 0,117 e *recall* de 0,185. Mesmo com todo o período de treino real, o Isolation Forest identificou menos de um quinto das anomalias introduzidas. As diferenças seguintes devem, por isso, ser interpretadas em relação a um desempenho de referência já baixo.

Nos cenários apenas reais, o F1 ficou entre 0,099 e 0,107 porque a *precision* e o *recall* variaram em sentidos opostos. Quando o histórico diminuiu de 20% para 5%, o *recall* aumentou de 0,353 para 0,466, enquanto a *precision* permaneceu entre 0,068 e 0,077.

Uma explicação possível está no limiar calculado a partir das pontuações de treino. Com uma janela curta, esse limiar pode levar o modelo a assinalar mais observações no teste, aumentando simultaneamente os verdadeiros e os falsos positivos. Esta hipótese é compatível com o aumento do *recall* e a redução da

precision, mas não foi testada porque a distribuição das pontuações não foi analisada.

Com a inclusão dos dados sintéticos, o desempenho diminuiu nos três níveis. O F1 desceu para 0,045 no cenário de 5% real + sintético, para 0,041 no cenário de 10% real + sintético e para 0,037 no cenário de 20% real + sintético.

A *precision* aumentou com o sintético nos três níveis: de 0,068 para 0,090, de 0,077 para 0,079 e de 0,071 para 0,094. Os aumentos foram inferiores ao desvio-padrão entre *splits* das mesmas células e não compensaram a redução do *recall*.

A redução do F1 não ocorreu da mesma forma em todos os edifícios. Nos cenários com sintético, o F1 foi zero em 9, 11 e 10 dos 25 casos edifício-*split*, nos níveis de 5%, 10% e 20%, sempre porque o modelo não identificou nenhuma anomalia verdadeira. Nos cenários treinados apenas com histórico real escasso, o F1 foi zero apenas em dois casos do nível de 20%. Estes valores contribuíram diretamente para a redução das médias dos cenários com sintético.

A última coluna da Tabela 9 apresenta o F1 obtido com *contamination*=0,008 e com *contamination*=0,012, ou seja, 20% abaixo e 20% acima do valor base. São duas avaliações adicionais e não os limites de um intervalo de confiança. O F1 do valor base, 0,01, pode, por isso, ficar fora dos dois valores apresentados.

Tabela 9: Resultados da detecção de anomalias

Cenário	<i>Precision</i> média	<i>Recall</i> médio	F1 médio	F1 com contaminação 0,008; 0,012
100% real	0,117 ± 0,026	0,185 ± 0,065	0,117 ± 0,025	0,106; 0,116
5% real	0,068 ± 0,030	0,466 ± 0,133	0,099 ± 0,037	0,098; 0,098
5% real + sintético	0,090 ± 0,049	0,114 ± 0,074	0,045 ± 0,021	0,033; 0,058
10% real	0,077 ± 0,046	0,402 ± 0,074	0,107 ± 0,063	0,107; 0,112
10% real + sintético	0,079 ± 0,067	0,088 ± 0,053	0,041 ± 0,025	0,030; 0,046
20% real	0,071 ± 0,041	0,353 ± 0,066	0,100 ± 0,047	0,099; 0,100
20% real + sintético	0,094 ± 0,076	0,080 ± 0,057	0,037 ± 0,027	0,031; 0,045

Nota: cada valor corresponde à média, entre os cinco *splits*, do valor médio por edifício de cada métrica, seguida do desvio-padrão entre *splits*. O desvio-padrão descreve a variação entre *splits* e não a dispersão entre edifícios. Por esse motivo, o F1 médio não corresponde à média harmónica das colunas agregadas de *precision* e *recall*. No cenário de referência, a *precision* média (0,1172) e o F1 médio (0,1167) coincidem apenas após arredondamento a três casas decimais.

4.6.2 Interpretação da queda do F1

A redução do F1 resultou principalmente da redução do *recall*. Com o sintético, o *recall* médio desceu para 0,114, 0,088 e 0,080 nos níveis de 5%, 10% e 20%, respetivamente. O modelo identificou, portanto, menos anomalias verdadeiras quando o treino incluiu o complemento sintético.

No *split* 500, as séries sintéticas apresentaram maior dispersão e uma cauda superior mais pesada do que as séries reais, conforme a Secção 4.2.1. A redução do *recall* é compatível com a hipótese de que essa dispersão tenha alargado a região considerada normal pelo Isolation Forest, levando o modelo a classificar mais anomalias como normais. A conversão para a escala de cada edifício pode atuar no mesmo sentido. O perfil sintético foi normalizado pela média dos edifícios de calibração e convertido pela mediana das medianas horárias do edifício avaliado, conforme a Secção 3.6.6. Em séries assimétricas, o nível do complemento pode, por isso, afastar-se do histórico real. Os dois fatores são distintos: a maior dispersão é medida no espaço normalizado, antes da conversão de escala ser aplicada, pelo que podem atuar por vias diferentes, ainda que no mesmo sentido.

Os resultados mostram apenas a direção das diferenças: a redução do histórico real alterou pouco o F1, porque o aumento do *recall* compensou a perda de *precision*, e a degradação surgiu quando o complemento sintético foi acrescentado. O desenho experimental não previu, nesta tarefa, um cenário de controlo sem dependência temporal, conforme assumido nas delimitações metodológicas da Secção 3.15. Não é possível, por isso, determinar se a degradação decorre da estrutura das séries geradas, da sua dispersão ou da extensão da janela de treino com observações que não são medições do edifício.

A sensibilidade da redução do F1 ao parâmetro de contaminação foi avaliada com os valores 0,008 e 0,012, conforme a última coluna da Tabela 9. Nos dois valores, o F1 dos cenários com sintético permaneceu abaixo do F1 dos cenários apenas

reais.

Estes resultados não permitem concluir que os dados sintéticos prejudiquem sempre a deteção de anomalias. A conclusão aplica-se apenas ao gerador estatístico-temporal, ao Isolation Forest, às anomalias artificiais pontuais e às séries sintéticas usadas neste estudo.

4.7 Discussão dos resultados

O complemento sintético produziu resultados opostos nas duas tarefas: reduziu o NRMSE do Prophet e o F1-score do Isolation Forest, sobretudo devido à queda do *recall*. Este contraste mostra que a utilidade dos dados sintéticos deve ser medida na tarefa final e não apenas pela semelhança com os dados reais.

Na previsão, o principal resultado metodológico decorre do cenário de controlo. Os cenários com ruído branco ficaram próximos dos cenários com dados sintéticos, sem diferença estatisticamente significativa entre os dois. Sem esse controlo, a redução do erro poderia ser interpretada como prova direta da qualidade do gerador; com ele, essa conclusão deixa de ser sustentada. Os dados sintéticos reduziram o erro face ao treino escasso, mas não ficou demonstrado que fossem superiores ao preenchimento da mesma janela de treino com observações sem estrutura temporal.

A estrutura que separa os dois complementos resulta sobretudo do perfil horário e semanal e da componente residual AR(1): nas cinco calibrações, o coeficiente térmico ficou abaixo de 0,0025 em módulo.

Li et al. [3] também observaram benefícios da geração de dados em cenários de escassez com o BDG2. Nesta dissertação, o sintético reduziu igualmente o erro face ao treino escasso. A inclusão do ruído branco acrescenta, contudo, uma comparação ausente nesse estudo e impede atribuir a melhoria especificamente à estrutura temporal do gerador.

Na previsão, a redução do erro é compatível com a reposição da janela de treino com mais observações, que dá ao Prophet uma sequência mais longa para estimar a tendência e as sazonalidades; o controlo não permitiu atribuir essa redução à estrutura das séries acrescentadas. Na deteção, o mesmo reforço acompanha uma queda do *recall*, sem que exista um controlo equivalente que permita identificar a causa.

Alguns trabalhos acrescentam ao treino exemplos sintéticos de falhas ou situações raras [16, 27]. Nesta dissertação, o sintético reforçou apenas os exemplos considerados normais. O resultado negativo não exclui outras formas de utilização, mas mostra que o gerador, a dispersão das séries, o modelo de deteção e o tipo de anomalia devem ser avaliados em conjunto antes de reforçar o treino.

5. Conclusões

5.1 Síntese do trabalho realizado

Esta dissertação avaliou a utilização de dados sintéticos em duas tarefas da gestão energética de edifícios, a previsão do consumo e a deteção de anomalias, num contexto de pouco histórico real para treino. O estudo recorreu ao *dataset* BDG2 e restringiu a análise a edifícios da tipologia de educação.

A metodologia separou os edifícios usados na calibração do gerador dos edifícios de avaliação. As séries sintéticas combinaram padrões horários e semanais, temperatura exterior e uma componente residual com dependência temporal. Entraram apenas no período de treino, enquanto a avaliação incidiu sempre no período de teste real.

Foram testadas diferentes percentagens de histórico real. Na previsão, o complemento sintético foi ainda comparado com um cenário de ruído branco. Na deteção de anomalias, avaliou-se se a inclusão do sintético no treino alterava a *precision*, o *recall* e o F1-score do Isolation Forest no período de teste.

O trabalho incluiu a preparação das séries reais de consumo, a construção de um gerador estatístico-temporal e a avaliação do efeito do complemento nas duas tarefas, conforme os objetivos definidos no Capítulo 1.

5.2 Resposta à questão de investigação

A questão que orientou a dissertação foi a seguinte:

Qual é o efeito dos dados sintéticos, gerados a partir de padrões de um conjunto de edifícios de calibração, no desempenho de modelos de previsão do consumo energético e de deteção de anomalias quando aplicados a edifícios distintos, em cenários de disponibilidade limitada de dados históricos?

O efeito dos dados sintéticos foi diferente nas duas tarefas.

Na previsão do consumo, o Prophet registou erros elevados nos cenários treina-

dos apenas com pequenas frações de histórico real. Com o complemento sintético, o erro desceu e aproximou-se do cenário de referência. O controlo baseado em ruído branco obriga a qualificar esta conclusão: os cenários com ruído apresentaram valores próximos dos obtidos com dados sintéticos, e a diferença não foi estatisticamente significativa. A resposta para a previsão deve, por isso, ser formulada com prudência: o reforço reduziu o erro face ao treino escasso, mas não ficou demonstrado um contributo da estrutura temporal do gerador para além da reposição da janela de treino com mais observações.

Na deteção de anomalias, a inclusão do sintético reduziu o F1-score nos três níveis de escassez, principalmente pela queda do *recall*. Porém, o ponto de partida era baixo: com todo o período de treino real, o *recall* médio foi de 0,185.

Os resultados não sustentam uma conclusão comum às duas tarefas. Na previsão, o sintético reduziu o erro face ao treino escasso, embora sem vantagem demonstrada face ao ruído branco. Na deteção de anomalias, reduziu o F1-score. A utilização do complemento deve, assim, ser avaliada separadamente para cada tarefa, modelo e configuração de treino.

5.3 Principais conclusões

Dos resultados retiram-se três conclusões principais.

O cenário de controlo alterou a interpretação dos resultados da previsão. A comparação entre o treino com pouco histórico real e o treino complementado com dados sintéticos, por si só, levaria a atribuir a redução do erro ao gerador. Porém, a proximidade dos resultados obtidos com dados sintéticos e com o controlo mostra que essa interpretação não é suficiente. Mesmo com o controlo, o desenho experimental não permite separar o efeito da extensão da janela de treino, da temperatura disponível nesse período e do número de observações acrescentadas.

A separação entre calibração e avaliação reduziu o risco de validação circular. Os parâmetros do gerador foram estimados num grupo de edifícios e aplicados a edifícios distintos, sem utilizar o consumo dos edifícios de avaliação na calibração. Esta separação permitiu verificar se os padrões estimados num conjunto de edifícios eram úteis quando transferidos para outros edifícios da mesma tipologia.

Por fim, o mesmo complemento produziu efeitos diferentes nas duas tarefas. Nas

condições estudadas, os dados sintéticos reduziram o erro de previsão, mas diminuíram o F1-score na deteção de anomalias, sobretudo devido à redução do *recall*. O desenho experimental permitiu identificar este contraste, mas não determinar a sua causa. Assim, uma melhoria observada numa tarefa não permite assumir que os mesmos dados sintéticos serão úteis noutra.

5.4 Limitações do estudo

Os resultados devem ser lidos em conjunto com as decisões metodológicas descritas na Secção 3.15. Entre elas estão a utilização de um gerador estatístico-temporal, em vez de uma simulação física; o tratamento da temperatura ao nível do *site*, assumida como conhecida durante todo o período analisado; e o recurso a anomalias artificiais na avaliação da deteção.

Como se indicou na Secção 3.15, o cenário de controlo existiu apenas na previsão. Nesse contexto, permitiu contrastar o reforço sintético com um complemento aleatório, ainda que não isolasse todos os fatores. Na deteção de anomalias não existe um controlo equivalente, pelo que a causa da redução do F1-score não ficou identificada.

Cada *split* incluiu apenas cinco edifícios de avaliação. A repetição com cinco sementes permitiu alterar a composição dos grupos, mas não permite generalizar diretamente os resultados para conjuntos maiores de edifícios.

Na deteção de anomalias, a variação entre edifícios foi maior do que a variação entre as médias dos *splits* apresentada na Tabela 9. Em 30 dos 75 casos edifício-*split* com sintético (40%), o modelo não identificou uma única anomalia verdadeira. A redução média do F1 repetiu-se nos três níveis, mas estes resultados não permitem antecipar a dimensão da redução noutros conjuntos de edifícios.

A separação *held-out* foi feita ao nível do edifício e não ao nível do *site*. Edifícios do mesmo *site* podiam, assim, partilhar a mesma série meteorológica. Uma separação por *site* impediria a partilha da mesma série meteorológica entre os dois grupos e tornaria a avaliação mais exigente.

A conversão das séries sintéticas para a escala de cada edifício usou apenas a fração de consumo real disponível em cada cenário. Esta regra impediu que valores de consumo posteriores entrassem no treino. Como a conversão usou

uma mediana da janela inicial, o nível da série sintética podia afastar-se do nível do restante período de treino quando essa janela não representava o consumo posterior. A garantia aplica-se apenas ao consumo: a temperatura, discutida na Secção 3.15, foi assumida como disponível em todo o treino e teste.

A análise estatística é limitada pelo número de edifícios e pela dependência parcial entre *splits*. Como se notou na Secção 3.13, com cinco pares o teste bilateral de Wilcoxon não pode produzir um valor de p inferior a 0,0625, e os p -valores combinados pelo método de Fisher não são totalmente independentes. A repetição permitiu verificar se a direção das diferenças entre cenários se mantinha em grupos distintos, sem constituir prova de generalização.

5.5 Trabalho futuro

Um primeiro caminho é testar geradores que representem diferenças entre edifícios. O gerador usado nesta dissertação é simples de interpretar, mas produz séries mais dispersas do que as reais. Modelos condicionados por metadados, como o de Fu et al. [18], podem usar a tipologia, a área, a utilização ou outras propriedades disponíveis para ajustar as séries ao edifício-alvo. A capacidade desses modelos para reduzir a dispersão deve ser avaliada nas séries geradas e no desempenho nas tarefas finais. Porém, o método exigiria um conjunto de calibração muito superior aos sete edifícios usados nesta dissertação.

A temperatura exterior deve também ser modelada com mais detalhe. No gerador, o efeito térmico foi estimado através de um único coeficiente, calculado a partir dos edifícios de calibração de cada *split*. Podem ser testados coeficientes por edifício, por grupo de edifícios ou por estação do ano, mantendo sempre a separação entre treino e teste, para não introduzir *data leakage*.

O estudo deve ser alargado a outras tipologias. A restrição a edifícios de educação ajudou a controlar a heterogeneidade, mas não permite saber se a redução do erro na previsão e a queda do F1-score na deteção também ocorrem em escritórios, espaços comerciais, edifícios públicos ou infraestruturas com horários menos regulares.

Os mesmos cenários de previsão devem ser repetidos com modelos diferentes do Prophet. A comparação mostraria se a redução do erro face ao treino escasso e a proximidade entre o sintético e o controlo dependem do modelo escolhido.

Na deteção de anomalias, a prioridade é validar os modelos com anomalias reais previamente identificadas. Sem essa informação, podem ser criadas perturbações mais variadas, com falhas graduais, falhas prolongadas, alterações de regime e desvios dependentes da hora do dia. Um cenário de controlo com ruído branco, análogo ao adotado na previsão, permitiria ainda contrastar o reforço sintético com um complemento sem dependência temporal.

Deve também ser avaliada a quantidade de dados sintéticos acrescentada ao treino. Em vez de preencher toda a janela em falta com séries geradas, as experiências podem comparar percentagens menores, ponderações diferentes e a escolha de séries com distribuição ou perfil horário mais próximos do edifício avaliado. O objetivo é verificar se alguma destas variantes mantém a redução do NRMSE sem produzir a mesma queda do F1-score.

5.6 Considerações finais

Esta dissertação mostra que a utilidade dos dados sintéticos deve ser demonstrada na tarefa final e através de uma avaliação baseada em dados reais. Nas condições estudadas, o complemento apresentou efeitos distintos na previsão e na deteção de anomalias, pelo que a sua utilização deve ser validada para cada modelo, tarefa e configuração de treino.

Bibliografia

- [1] L. Zhang, J. Wen, Y. Li, J. Chen, Y. Ye, Y. Fu, and W. Livingood, "A review of machine learning in building load prediction," *Applied Energy*, vol. 285, p. 116452, 2021, <https://doi.org/10.1016/j.apenergy.2021.116452>.
- [2] H. Zhong, J. Wang, H. Jia, Y. Mu, and S. Lv, "Vector field-based support vector regression for building energy consumption prediction," *Applied Energy*, vol. 242, pp. 403–414, 2019, <https://doi.org/10.1016/j.apenergy.2019.03.078>.
- [3] G. Li, L. Zhan, X. Fang, J. Gao, C. Xu, X. He, J. Deng, and C. Xiong, "Performance comparison on improved data-driven building energy prediction under data shortage scenarios in four perspectives: Data generation, incremental learning, transfer learning, and physics-informed," *Energy*, vol. 312, p. 133640, 2024, <https://doi.org/10.1016/j.energy.2024.133640>.
- [4] C. Miller, A. Kathirgamanathan, B. Picchetti, P. Arjunan, J. Y. Park, Z. Nagy, P. Raftery, B. W. Hobson, Z. Shi, and F. Meggers, "The Building Data Genome Project 2, energy meter data from the ASHRAE Great Energy Predictor III competition," *Scientific Data*, vol. 7, no. 1, p. 368, 2020, <https://doi.org/10.1038/s41597-020-00712-x>.
- [5] S. J. Taylor and B. Letham, "Forecasting at scale," *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018, <https://doi.org/10.1080/00031305.2017.1380080>.
- [6] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest," in *2008 Eighth IEEE International Conference on Data Mining*. IEEE, 2008, pp. 413–422, <https://doi.org/10.1109/ICDM.2008.17>.
- [7] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time series analysis: Forecasting and control*, 5th ed. John Wiley & Sons, 2016.
- [8] H. S. Oliveira and H. P. Oliveira, "Transformers for energy forecast," *Sensors*, vol. 23, no. 15, p. 6840, 2023, <https://doi.org/10.3390/s23156840>.

- [9] J. Huang and S. Kaewunruen, "Forecasting energy consumption of a public building using Transformer and support vector regression," *Energies*, vol. 16, no. 2, p. 966, 2023, <https://doi.org/10.3390/en16020966>.
- [10] G. Pinto, Z. Wang, A. Roy, T. Hong, and A. Capozzoli, "Transfer learning for smart buildings: A critical review of algorithms, applications, and future perspectives," *Advances in Applied Energy*, vol. 5, p. 100084, 2022, <https://doi.org/10.1016/j.adapen.2022.100084>.
- [11] Z. Xing, Y. Pan, Y. Yang, X. Yuan, Y. Liang, and Z. Huang, "Transfer learning integrating similarity analysis for short-term and long-term building energy consumption prediction," *Applied Energy*, vol. 365, p. 123276, 2024, <https://doi.org/10.1016/j.apenergy.2024.123276>.
- [12] M. Stenger, R. Leppich, I. Foster, S. Kounev, and A. Bauer, "Evaluation is key: A survey on evaluation measures for synthetic time series," *Journal of Big Data*, vol. 11, p. 66, 2024, <https://doi.org/10.1186/s40537-024-00924-7>.
- [13] M. Turowski, B. Heidrich, L. Weingärtner, L. Springer, K. Phipps, B. Schäfer, R. Mikut, and V. Hagenmeyer, "Generating synthetic energy time series: A review," *Renewable and Sustainable Energy Reviews*, vol. 206, p. 114842, 2024, <https://doi.org/10.1016/j.rser.2024.114842>.
- [14] G. Iglesias, E. Talavera, Á. González-Prieto, A. Mozo, and S. Gómez-Canaval, "Data augmentation techniques in time series domain: A survey and taxonomy," *Neural Computing and Applications*, vol. 35, no. 14, pp. 10 123–10 145, 2023, <https://doi.org/10.1007/s00521-023-08459-3>.
- [15] H. Fang, H. Tan, R. Kosonen, X. Yuan, K. Jiang, and R. Ding, "Study of the data augmentation approach for building energy prediction beyond historical scenarios," *Buildings*, vol. 13, no. 2, p. 326, 2023, <https://doi.org/10.3390/buildings13020326>.
- [16] J. Han and A. Chong, "Hybrid-CGAN: A hybrid approach combining simulation and generative adversarial networks for fault detection and diagnosis in buildings," *Energy and Buildings*, vol. 335, p. 115531, 2025, <https://doi.org/10.1016/j.enbuild.2025.115531>.
- [17] T. Kang and K. Song, "Data augmentation using multivariate time series decomposition for predicting daily energy consumption of new build-

- dings,” *Buildings*, vol. 15, no. 19, p. 3467, 2025, <https://doi.org/10.3390/buildings15193467>.
- [18] C. Fu, H. Kazmi, M. Quintana, and C. Miller, “Creating synthetic energy meter data using conditional diffusion and building metadata,” *Energy and Buildings*, vol. 312, p. 114216, 2024, <https://doi.org/10.1016/j.enbuild.2024.114216>.
- [19] Z. C. Lipton and J. Steinhardt, “Troubling trends in machine learning scholarship,” *ACM Queue*, vol. 17, no. 1, pp. 45–77, 2019, <https://doi.org/10.1145/3317287.3328534>.
- [20] M. Ferrari Dacrema, P. Cremonesi, and D. Jannach, “Are we really making much progress? A worrying analysis of recent neural recommendation approaches,” in *Proceedings of the 13th ACM Conference on Recommender Systems*, 2019, pp. 101–109, <https://doi.org/10.1145/3298689.3347058>.
- [21] S. Kim, K. Choi, H.-S. Choi, B. Lee, and S. Yoon, “Towards a rigorous evaluation of time-series anomaly detection,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 36, no. 7, 2022, pp. 7194–7201, <https://doi.org/10.1609/aaai.v36i7.20680>.
- [22] Y. Kang, R. J. Hyndman, and F. Li, “GRATIS: GeneRAting Tlme series with diverse and controllable characteristics,” *Statistical Analysis and Data Mining*, vol. 13, no. 4, pp. 354–376, 2020, <https://doi.org/10.1002/sam.11461>.
- [23] A. Alaa, B. Van Breugel, E. S. Saveliev, and M. van der Schaar, “How faithful is your synthetic data? Sample-level metrics for evaluating and auditing generative models,” in *Proceedings of the 39th International Conference on Machine Learning*, vol. 162, 2022, pp. 290–306, <https://proceedings.mlr.press/v162/alaa22a.html>.
- [24] Y. Himeur, K. Ghanem, A. Alsalemi, F. Bensaali, and A. Amira, “Artificial intelligence based anomaly detection of energy consumption in buildings: A review, current trends and new perspectives,” *Applied Energy*, vol. 287, p. 116601, 2021, <https://doi.org/10.1016/j.apenergy.2021.116601>.
- [25] R. Wu and E. J. Keogh, “Current time series anomaly detection benchmarks are flawed and are creating the illusion of progress,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 3, pp. 2421–2429, 2023, <https://doi.org/10.1109/TKDE.2021.3112126>.

- [26] S. Schmidl, P. Wenig, and T. Papenbrock, “Anomaly detection in time series: A comprehensive evaluation,” *Proceedings of the VLDB Endowment*, vol. 15, no. 9, pp. 1779–1797, 2022, <https://doi.org/10.14778/3538598.3538602>.
- [27] C. Tian, M. Li, A. Yan, H. Zhang, and Q. Liu, “Research on anomaly detection of building energy consumption integrating density-aware oversampling and improved positional encoding,” *Energy and Buildings*, vol. 353, p. 116922, 2026, <https://doi.org/10.1016/j.enbuild.2025.116922>.
- [28] N. V. Smirnov, “Table for estimating the goodness of fit of empirical distributions,” *Annals of Mathematical Statistics*, vol. 19, no. 2, pp. 279–281, 1948, <https://doi.org/10.1214/aoms/1177730256>.
- [29] S. S. Shapiro and M. B. Wilk, “An analysis of variance test for normality (complete samples),” *Biometrika*, vol. 52, no. 3–4, pp. 591–611, 1965, <https://doi.org/10.1093/biomet/52.3-4.591>.
- [30] F. Wilcoxon, “Individual comparisons by ranking methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945, <https://doi.org/10.2307/3001968>.
- [31] R. A. Fisher, *Statistical methods for research workers*, 4th ed. Oliver & Boyd, 1932.
- [32] R. Rosenthal, *Meta-analytic procedures for social research*, rev. ed. Sage Publications, 1991.
- [33] J. Cohen, *Statistical power analysis for the behavioral sciences*, 2nd ed. Lawrence Erlbaum Associates, 1988.
- [34] B. Efron and R. J. Tibshirani, *An introduction to the bootstrap*. Chapman & Hall/CRC, 1994.

Glossário

cenário de controlo Cenário da previsão em que o treino é complementado com ruído branco em vez de séries sintéticas, mantendo a mesma extensão da janela de treino, para comparar o efeito da estrutura temporal com o da reposição da janela

data augmentation Reforço do conjunto de treino com séries geradas artificialmente, para compensar a escassez de histórico real. O seu efeito é avaliado pela utilidade na tarefa final e não apenas pela semelhança estatística com os dados reais

data leakage Utilização indevida, durante a preparação ou o treino, de informação que deveria permanecer reservada à avaliação. Neste estudo, o risco foi reduzido através da separação entre os edifícios de calibração e de avaliação e da utilização exclusiva de dados reais no teste

gerador estatístico-temporal Gerador de séries sintéticas que combina perfis horários e semanais, o efeito da temperatura exterior e uma componente residual com dependência temporal. É transparente, por se conhecerem exatamente as componentes que introduz

held-out Conjunto de edifícios reservado, não usado na calibração do gerador, sobre o qual se avaliam a previsão e a deteção de anomalias com dados reais no teste

ruído branco Sequência de valores sem estrutura temporal usada como complemento de controlo no treino

split Cada repartição dos edifícios em sete edifícios de calibração e cinco de avaliação, definida por uma semente. A repetição do procedimento em cinco *splits* permite analisar a estabilidade dos resultados perante diferentes composições dos grupos

Apêndices

Apêndice A. *Pipeline* experimental e scripts

Este apêndice documenta o *pipeline* experimental descrito no Capítulo 3 e usado na produção dos resultados apresentados no Capítulo 4, sem reproduzir o código integral, que permanece no repositório do projeto. Descrevem-se o inventário dos onze scripts, a respetiva função, a sequência de execução e a ligação aos elementos do corpo da dissertação.

A.1 Inventário dos scripts

A Tabela 10 apresenta o inventário dos scripts do *pipeline*, com a respetiva função.

Tabela 10: Inventário dos scripts do *pipeline*

Script	Tipo	Função	Entradas principais	Saídas principais
1.selecao_edificios.py	Principal	Seleção dos edifícios de educação e divisão calibração/avaliação por semente	electricity_cleaned.csv	01_1_*, 01_2_*
2.data_modelacao.py	Principal	Construção da base de modelação (consumo e temperatura)	consumo, weather.csv	02_base_modelacao*
3.analise_exploratoria.py	Auxiliar	Análise exploratória sobre o <i>split</i> 500	base de modelação	figuras exploratórias

continua na página seguinte

Tabela 10 — continuação

Script	Tipo	Função	Entradas principais	Saídas principais
4.gerar_dados.py	Principal	Gerador estatístico-temporal (perfil, temperatura, AR(1))	base + calibração	04_series_sinteticas*, 04_1_parametros*
5.validar_dados.py	Auxiliar	Validação das séries (distribuição, KS, ACF, RMSE)	reais e sintéticas	05_*
6.experiencias_previsao.py	Principal	Previsão com Prophet nos cenários de escassez e de reforço	reais e sintéticas	06_*
7.analise_edificio.py	Auxiliar	Análise por edifício, ganhos e <i>bootstrap</i>	resultados de previsão	07_*
8.testes_estatisticos.py	Auxiliar	Testes estatísticos (Shapiro, Wilcoxon, Fisher, tamanho de efeito)	resultados de previsão	08_*
9.detecao_anomalias.py	Principal	Deteção com Isolation Forest e injeção de anomalias	reais e sintéticas	09_*
10.multiplas_execucoes.py	Coordenação	Execução repetida do <i>pipeline</i> nas cinco sementes e agregação por <i>split</i>	scripts 1, 2, 4, 6, 9	10_*
11.execucoes_final.py	Consolidação	Produção das tabelas e figuras finais consolidadas	10_1_*, 10_2_*	11_1_*, 11_2_*, figura_06_1_*, figura_06_2_*

A.2 Sequência de execução

Por cada semente, o `10.multiplas_execucoes.py` corre a cadeia principal $1 \rightarrow 2 \rightarrow 4 \rightarrow 6 \rightarrow 9$ e agrega os resultados por *split*. Como a semente 500 é a última da lista, os ficheiros que permanecem em `ficheiros_intermedios` após a conclusão do script 10 correspondem a esse *split*; são esses ficheiros que alimentam os scripts 3 e 5, responsáveis pela análise exploratória e pela validação do gerador. Os scripts 7 e 8 usam os resultados de previsão consolidados pelo script 10, enquanto o script 11 produz as tabelas e figuras finais a partir dos resultados agregados de previsão e deteção. Uma sequência completa que respeita estas dependências é $10 \rightarrow 3 \rightarrow 5 \rightarrow 7 \rightarrow 8 \rightarrow 11$. Esta sequência foi executada de raiz a partir dos ficheiros originais do BDG2, num ambiente independente do usado nas experiências finais; o resultado consta da Secção C.5.

A.3 Composição dos *splits*

Cada *split* corresponde a uma semente (42, 100, 200, 400 e 500) e reparte os edifícios em sete de calibração e cinco de avaliação. Ao todo, as cinco repartições incluem 60 seleções, correspondentes a 55 edifícios distintos. Nos conjuntos de avaliação, as 25 seleções correspondem a 23 edifícios distintos, conforme a Secção 3.13. A composição integral por semente consta dos ficheiros `01_1_edificios_calibracao_divisao<semente>.csv` e `01_2_edificios_teste_divisao<semente>.csv` do repositório.

A.4 Ligações ao corpo

A Tabela 11 relaciona as saídas dos scripts diretamente associadas às tabelas e figuras dos Capítulos 3 e 4. A numeração é obtida por referência cruzada.

Tabela 11: Ligação das saídas dos scripts aos elementos dos Capítulos 3 e 4

Script	Elementos sustentados
3	Figuras 2–4
5	Tabela 5; Figuras 5–8
6	Dados de previsão por execução, agregados pelo script 10 e resumidos pelo script 11
7	Tabela 7; Figuras 11, 12 e 13
8	Tabela 8; Figuras 14–15
9	Dados de deteção por execução, agregados pelo script 10 e resumidos pelo script 11
10	Agregação por <i>split</i> dos resultados de previsão e deteção usados pelos scripts 7, 8 e 11
11	Tabelas 6 e 9; Figuras 9 e 10

Apêndice B. Gerador e configuração experimental

Este apêndice reúne o pseudocódigo do gerador estatístico-temporal e as configurações completas usadas nas experiências, evitando repetir as fórmulas e as explicações já apresentadas no Capítulo 3.

B.1 Pseudocódigo do gerador

Entradas: as séries de consumo e de temperatura dos edifícios de calibração, os *timesteps* e a temperatura do *site* dos edifícios de avaliação e o coeficiente autorregressivo $\varphi = 0,85$.

1. Normalizar o consumo de calibração pela respetiva média;
2. Estimar o perfil por hora e dia da semana, como média por par (hora, dia da semana), suavizada por média móvel de três posições; aplicar o valor mínimo de 0,1 apenas quando o perfil é usado como denominador na calibração do resíduo;
3. Ajustar o efeito térmico por regressão linear do consumo normalizado, já corrigido do perfil, na temperatura, obtendo β e a ordenada na origem, com β limitado ao intervalo $[-0,05; 0,05]$;
4. Estimar o desvio do resíduo multiplicativo σ_{res} ;
5. Calcular, para caracterização da calibração, os percentis 1 e 99,9 do consumo normalizado;
6. Para cada edifício de avaliação e cada instante, obter a componente temporal a partir do perfil, atribuindo o valor 1,0 aos pares hora/dia sem correspondência, e a componente térmica a partir da temperatura, limitada ao mínimo de 0,1;
7. Gerar a componente residual por um processo autorregressivo de primeira ordem (Secção 3.6.5): dimensionar o desvio-padrão da inovação como $\sigma_{\eta} = \sigma_{\text{res}}\sqrt{1 - \varphi^2}$, inicializar $e_0 = \eta_0$ e, para $t > 0$, aplicar $e_t = \varphi e_{t-1} + \eta_t$, com $\varphi = 0,85$;

8. Limitar a componente residual multiplicativa $1 + e_t$ ao mínimo de 0,1 e combiná-la com as restantes componentes, obtendo a série sintética normalizada.

Saída: uma série sintética de consumo normalizado para cada edifício de avaliação.

B.2 Parâmetros do gerador

Os valores da ordenada na origem, de σ_{res} e dos percentis apresentados na Tabela 12 correspondem à calibração do *split* 500, usada na análise exploratória e na validação. A tabela indica ainda o declive dessa calibração e o intervalo observado nas cinco.

Tabela 12: Parâmetros e estatísticas de calibração do gerador estatístico-temporal

Parâmetro	Valor
Coeficiente do efeito da temperatura (β), <i>split</i> 500	-0,00197
Intervalo de β nas cinco calibrações	$[-0,00197; 0,00245]$
Ordenada na origem da temperatura	1,02722
Desvio do resíduo multiplicativo (calibração)	0,4024
Percentil 1 do consumo normalizado (calibração)	0,0005
Percentil 99,9 do consumo normalizado (calibração)	4,6033
Coeficiente de autocorrelação AR(1)	0,85
Limite imposto ao coeficiente térmico	$[-0,05; 0,05]$

Nota: os percentis são apresentados para caracterização da calibração e não foram utilizados para recortar as séries sintéticas. Os declives estimados nas cinco calibrações foram 0,00245 (semente 42), 0,00129 (100), 0,00012 (200), -0,00073 (400) e -0,00197 (500). O desvio do resíduo multiplicativo caracteriza os edifícios de calibração e é distinto do desvio-padrão das séries reais de avaliação, apresentado na Tabela 5.

B.3 Configuração do Prophet

Na previsão foi usado o Prophet com os argumentos explicitamente definidos `daily_seasonality=True`, `weekly_seasonality=True` e `yearly_seasonality=False`. A temperatura do ar exterior foi acrescentada como regressor externo através de `add_regressor`. O parâmetro `changepoint_prior_scale` não foi passado nas execuções finais, permanecendo no valor por defeito do Prophet.

B.4 Configuração do Isolation Forest

Na detecção de anomalias foi usado o Isolation Forest instanciado com `contamination` igual a 0,01 na configuração base e `random_state` igual à semente de anomalias, definida pela variável de ambiente `ANOMALY_SEED` (ou `EXPERIMENT_SEED`, por defeito 42). Nas execuções múltiplas, `ANOMALY_SEED` recebe o valor 30000 mais a semente do *split*, pelo que o `random_state` do modelo varia com a semente. O consumo, o `lag_1` e o `lag_24` foram normalizados com `StandardScaler`, ajustado apenas com os dados de treino e aplicado ao teste. A hora do dia e o dia da semana foram reescalados para o intervalo entre 0 e 1. Os restantes parâmetros permaneceram nos valores por defeito da versão do `scikit-learn` utilizada. Na análise de sensibilidade, o parâmetro `contamination` tomou os valores 0,008 e 0,012, correspondentes a $0,01 \times 0,8$ e $0,01 \times 1,2$.

B.5 Sementes e injeção de anomalias

As experiências foram repetidas com as sementes 42, 100, 200, 400 e 500. Na detecção, a proporção de anomalias injetadas no período de teste foi de 0,01, com a regra de mínimo $n_{\text{anomalias}} = \max(1, \lfloor n_{\text{observações}} \times 0,01 \rfloor)$, que garante pelo menos uma anomalia por série avaliada. A semente de injeção de cada edifício foi calculada como `ANOMALY_SEED + 10000 + índice do edifício`, pelo que os pontos injetados variam entre edifícios e se mantêm reprodutíveis, embora dependam da respetiva ordem de processamento.

Nas execuções múltiplas, o script atribui `GENERATOR_SEED`, `FORECAST_SEED` e `ANOMALY_SEED` com os valores $10000 + s$, $20000 + s$ e $30000 + s$, em que s é a semente do *split*. No cenário de controlo com ruído branco, o gerador aleatório é reinicializado, para cada edifício e nível de escassez, com `FORECAST_SEED + 20000 + p`, em que p é a percentagem de histórico real. Como esta semente não depende do edifício, complementos de ruído com o mesmo comprimento partilham a mesma realização normalizada, depois ajustada à escala local de cada edifício. O ruído mantém-se sem ordem temporal dentro de cada série.

Apêndice C. Resultados complementares

Este apêndice reúne os resultados desagregados por *split* e por edifício que sustentam, no Capítulo 4, as sínteses agregadas. O detalhe integral permanece no repositório do projeto.

C.1 Previsão por *split*

Tabela 13: Resultados da previsão por *split*

Semente	Cenário	RMSE médio	NRMSE médio	NRMSE mediano	Ganho relativo face a 100% real (%)
42	5% – Apenas real	910,00	255,81	107,51	-1142,65
42	5% – Com ruído	131,13	29,92	29,31	-45,36
42	5% – Com sintético	142,62	32,32	27,41	-56,99
42	10% – Apenas real	1680,56	450,60	144,20	-2088,83
42	10% – Com ruído	128,06	28,89	27,79	-40,34
42	10% – Com sintético	142,82	32,21	24,46	-56,46
42	20% – Apenas real	409,78	94,59	105,74	-359,47
42	20% – Com ruído	119,47	25,81	25,04	-25,39
42	20% – Com sintético	129,87	28,31	22,53	-37,53
42	100% – Apenas real	93,26	20,59	18,27	0,00
100	5% – Apenas real	225,27	210,00	109,76	-368,77
100	5% – Com ruído	26,38	35,78	36,47	20,12
100	5% – Com sintético	43,44	36,32	31,68	18,93
100	10% – Apenas real	170,57	194,72	99,45	-334,67
100	10% – Com ruído	27,09	36,43	35,19	18,69
100	10% – Com sintético	44,11	38,38	35,73	14,32
100	20% – Apenas real	51,16	72,73	66,94	-62,34

continua na página seguinte

Tabela 13 — continuação

Semente	Cenário	RMSE médio	NRMSE médio	NRMSE mediano	Ganho relativo face a 100% real (%)
100	20% – Com ruído	27,41	38,43	37,50	14,21
100	20% – Com sintético	42,94	41,38	40,71	7,62
100	100% – Apenas real	35,87	44,80	28,65	0,00
200	5% – Apenas real	849,70	448,07	471,58	-1590,33
200	5% – Com ruído	37,94	36,61	38,00	-38,11
200	5% – Com sintético	45,47	39,80	34,40	-50,14
200	10% – Apenas real	175,08	117,04	115,50	-341,52
200	10% – Com ruído	35,98	35,43	34,91	-33,65
200	10% – Com sintético	43,48	37,83	31,17	-42,73
200	20% – Apenas real	122,29	148,80	200,51	-461,33
200	20% – Com ruído	32,57	32,45	30,44	-22,42
200	20% – Com sintético	40,17	35,63	28,18	-34,42
200	100% – Apenas real	25,29	26,51	18,00	0,00
400	5% – Apenas real	106,66	305,10	205,01	-630,42
400	5% – Com ruído	16,29	43,26	31,09	-3,57
400	5% – Com sintético	13,87	37,32	24,02	10,66
400	10% – Apenas real	236,33	721,83	168,29	-1628,07
400	10% – Com ruído	16,70	43,73	35,14	-4,70
400	10% – Com sintético	14,83	39,06	30,51	6,50
400	20% – Apenas real	116,93	332,65	174,87	-696,36
400	20% – Com ruído	16,97	43,81	39,38	-4,88
400	20% – Com sintético	14,81	38,67	33,00	7,41
400	100% – Apenas real	15,30	41,77	25,86	0,00
500	5% – Apenas real	873,91	203,02	99,47	-802,09
500	5% – Com ruído	129,19	33,94	36,07	-50,82
500	5% – Com sintético	116,08	29,09	32,45	-29,28

continua na página seguinte

Tabela 13 — continuação

Semente	Cenário	RMSE médio	NRMSE médio	NRMSE mediano	Ganho relativo face a 100% real (%)
500	10% – Apenas real	1230,69	238,07	301,20	-957,85
500	10% – Com ruído	122,11	32,44	33,82	-44,12
500	10% – Com sintético	114,80	29,14	34,56	-29,46
500	20% – Apenas real	477,37	123,71	105,74	-449,69
500	20% – Com ruído	118,27	30,73	32,59	-36,56
500	20% – Com sintético	114,68	29,50	36,29	-31,10
500	100% – Apenas real	85,55	22,51	21,63	0,00

Nota: valores positivos indicam redução do NRMSE face ao cenário de referência (100% real); valores negativos indicam erro superior.

C.2 Ganhos por edifício no cenário de 20%

Tabela 14: Ganhos de NRMSE por edifício no cenário de 20%

Semente	Edifício	NRMSE real	NRMSE sintético	Ganho (%)
42	Fox_education_Nilda	69,03	22,53	67,36
42	Hog_education_Bruno	120,89	12,56	89,61
42	Moose_education_Clark	105,74	26,81	74,65
42	Peacock_education_ Ophelia	16,28	16,34	-0,33
42	Rat_education_Alfonso	160,99	63,33	60,66
100	Fox_education_Rudolph	157,24	45,73	70,92
100	Peacock_education_ Ophelia	16,28	15,97	1,92
100	Rat_education_Cecil	88,36	74,14	16,09
100	Rat_education_Deبرا	34,81	40,71	-16,94
100	Wolf_education_Katie	66,94	30,37	54,63
200	Bear_education_Gavin	247,04	14,66	94,07
200	Eagle_education_ Samantha	40,49	22,57	44,25
200	Hog_education_Jared	210,92	38,70	81,65

continua na página seguinte

Tabela 14 — continuação

Semente	Edifício	NRMSE real	NRMSE sintético	Ganho (%)
200	Robin_education_ Mercedes	45,02	28,18	37,41
200	Wolf_education_Eulalia	200,51	74,05	63,07
400	Fox_education_Kim	174,87	33,00	81,13
400	Lamb_education_Williams	1110,11	71,70	93,54
400	Moose_education_Marina	21,55	22,09	-2,50
400	Peacock_education_ Patience	33,59	19,71	41,30
400	Robin_education_Billi	323,13	46,87	85,50
500	Bull_education_Dakota	255,01	38,34	84,97
500	Moose_education_Clark	105,74	36,29	65,68
500	Peacock_education_Lyle	162,53	15,29	90,59
500	Robin_education_Megan	21,40	21,05	1,63
500	Wolf_education_Laurinda	73,87	36,55	50,52

Nota: $\text{Ganho (\%)} = (\text{NRMSE}_{\text{real}} - \text{NRMSE}_{\text{sintético}}) / \text{NRMSE}_{\text{real}} \times 100$. Valores positivos indicam redução do NRMSE com o reforço sintético; valores negativos indicam agravamento. Os identificadores surgem na forma completa; no corpo aparecem abreviados, sem o segmento *education*.

C.3 Testes de Wilcoxon por *split*

 Tabela 15: Testes de Wilcoxon da previsão por *split*

Nível	Semente	Comparação	<i>p</i> Wilco- xon	<i>r</i>	Classif.	Ganho médio (%)
5%	42	real escasso vs. real + sintético	0,1250	0,7839	Forte	51,94
5%	100	real escasso vs. real + sintético	0,1250	0,7839	Forte	65,04
5%	200	real escasso vs. real + sintético	0,0625	0,9045	Forte	81,46
5%	400	real escasso vs. real + sintético	0,0625	0,9045	Forte	81,36
5%	500	real escasso vs. real + sintético	0,1875	0,6633	Forte	37,12
10%	42	real escasso vs. real + sintético	0,0625	0,9045	Forte	74,01
10%	100	real escasso vs. real + sintético	0,0625	0,9045	Forte	66,75

continua na página seguinte

Tabela 15 — continuação

Nível	Semente	Comparação	<i>p</i> Wilcoxon	<i>r</i>	Classif.	Ganho médio (%)
10%	200	real escasso vs. real + sintético	0,0625	0,9045	Forte	61,17
10%	400	real escasso vs. real + sintético	0,0625	0,9045	Forte	78,12
10%	500	real escasso vs. real + sintético	0,0625	0,9045	Forte	74,29
20%	42	real escasso vs. real + sintético	0,1250	0,7839	Forte	58,39
20%	100	real escasso vs. real + sintético	0,1875	0,6633	Forte	25,32
20%	200	real escasso vs. real + sintético	0,0625	0,9045	Forte	64,09
20%	400	real escasso vs. real + sintético	0,1250	0,7839	Forte	59,79
20%	500	real escasso vs. real + sintético	0,0625	0,9045	Forte	58,68
5%	42	real + ruído vs. real + sintético	0,6250	0,3015	Moderado	-43,95
5%	100	real + ruído vs. real + sintético	0,8125	0,1809	Fraco	-41,83
5%	200	real + ruído vs. real + sintético	0,6250	0,3015	Moderado	-30,55
5%	400	real + ruído vs. real + sintético	0,0625	0,9045	Forte	16,05
5%	500	real + ruído vs. real + sintético	0,3125	0,5427	Forte	14,39
10%	42	real + ruído vs. real + sintético	0,6250	0,3015	Moderado	-48,97
10%	100	real + ruído vs. real + sintético	0,6250	0,3015	Moderado	-45,91
10%	200	real + ruído vs. real + sintético	0,8125	0,1809	Fraco	-28,99
10%	400	real + ruído vs. real + sintético	0,0625	0,9045	Forte	11,53
10%	500	real + ruído vs. real + sintético	0,1875	0,6633	Forte	11,06
20%	42	real + ruído vs. real + sintético	0,6250	0,3015	Moderado	-38,94
20%	100	real + ruído vs. real + sintético	0,6250	0,3015	Moderado	-49,12
20%	200	real + ruído vs. real + sintético	0,4375	0,4221	Moderado	-30,36

continua na página seguinte

Tabela 15 — continuação

Nível	Semente	Comparação	p Wilcoxon	r	Classif.	Ganho médio (%)
20%	400	real + ruído vs. real + sintético	0,0625	0,9045	Forte	11,69
20%	500	real + ruído vs. real + sintético	0,6250	0,3015	Moderado	5,63

Nota: em todas as linhas o resultado não é significativo a $\alpha = 0,05$. «Ganho médio (%)» é a média, entre os cinco edifícios, da variação relativa de NRMSE do segundo cenário face ao primeiro (denominador = primeiro cenário da coluna «Comparação»). Na comparação «real + ruído vs. real + sintético», os valores negativos indicam que o ruído branco obteve NRMSE inferior ao do sintético. Com cinco pares, p e r assumem um conjunto discreto reduzido de valores, no máximo oito, pelo que a sua repetição entre *splits* decorre da dimensão da amostra.

C.4 Detecção de anomalias por cenário e por *split*

 Tabela 16: Detecção de anomalias por cenário e por *split*

Semente	Cenário	<i>precision</i>	<i>recall</i>	F1	N.º de edifícios com F1 = 0
42	100% real	0,159	0,163	0,125	1
42	10% real	0,073	0,484	0,092	0
42	10% real + sint.	0,003	0,046	0,006	4
42	20% real	0,044	0,461	0,078	1
42	20% real + sint.	0,003	0,046	0,006	4
42	5% real	0,044	0,658	0,082	0
42	5% real + sint.	0,104	0,065	0,022	3
100	100% real	0,090	0,154	0,096	1
100	10% real	0,034	0,377	0,044	0
100	10% real + sint.	0,032	0,142	0,039	1
100	20% real	0,035	0,346	0,047	0
100	20% real + sint.	0,026	0,169	0,028	1
100	5% real	0,037	0,400	0,050	0
100	5% real + sint.	0,042	0,142	0,049	1
200	100% real	0,123	0,119	0,118	2
200	10% real	0,147	0,469	0,203	0

continua na página seguinte

Tabela 16 — continuação

Semente	Cenário	<i>precision</i>	<i>recall</i>	F1	N.º de edifícios com F1 = 0
200	10% real + sint.	0,062	0,108	0,074	2
200	20% real	0,129	0,281	0,159	0
200	20% real + sint.	0,115	0,085	0,079	2
200	5% real	0,112	0,488	0,150	0
200	5% real + sint.	0,034	0,142	0,054	2
400	100% real	0,103	0,203	0,091	0
400	10% real	0,037	0,379	0,066	0
400	10% real + sint.	0,160	0,124	0,050	1
400	20% real	0,046	0,343	0,078	0
400	20% real + sint.	0,155	0,082	0,037	0
400	5% real	0,081	0,488	0,113	0
400	5% real + sint.	0,138	0,206	0,073	0
500	100% real	0,112	0,288	0,153	1
500	10% real	0,092	0,304	0,129	0
500	10% real + sint.	0,136	0,019	0,034	3
500	20% real	0,100	0,336	0,140	1
500	20% real + sint.	0,170	0,019	0,035	3
500	5% real	0,065	0,296	0,098	0
500	5% real + sint.	0,133	0,016	0,027	3

Nota: *precision*, *recall* e F1 são médias entre os cinco edifícios de cada *split*. A última coluna conta, entre esses cinco, os que têm F1 exatamente nulo (por *recall* nulo), a partir dos ficheiros 09_isolation_forest_anomalias_por_edificio_divisao<semente>.csv. Nos cenários com reforço sintético, o total é 9, 11 e 10 nos níveis de 5%, 10% e 20%.

C.5 Execução de verificação

Depois de concluídas as experiências, o *pipeline* foi executado de novo a partir dos ficheiros originais do BDG2, numa máquina diferente e num ambiente instalado de raiz para o efeito. As versões das bibliotecas usadas constam do ficheiro `versoes_ambiente.txt` do repositório. A execução teve dois objetivos: verificar a reprodutibilidade dos resultados a partir dos dados públicos e avaliar o efeito de dois parâmetros fixados no desenho, o coeficiente de persistência da componente

residual e o `changepoint_prior_scale` do Prophet.

Os valores apresentados nesta secção provêm dessa execução e não substituem os das tabelas anteriores, obtidas na execução original. Cada comparação apresentada envolve apenas cenários obtidos na mesma execução.

C.5.1 Reprodutibilidade

Os parâmetros do gerador dependem apenas dos dados de entrada e das sementes, e reproduziram-se sem diferença: os valores da Tabela 12 coincidem com os da execução original. As métricas de validação do gerador da Tabela 5 coincidem igualmente, com desvios inferiores a 10^{-15} nas séries sintéticas e nulos nas séries reais. Na deteção de anomalias, os resultados agregados por *split* coincidiram sem qualquer diferença.

Na previsão, os valores de erro diferem. Tomando o NRMSE médio de cada cenário em cada *split*, a diferença relativa entre as duas execuções tem mediana de 0,08% e máximo de 4,11%; quatro dos cinquenta valores excedem 1% e nenhum excede 5%. As maiores diferenças ocorrem nos cenários treinados apenas com frações reduzidas de histórico real e são compatíveis com diferenças de convergência do Prophet entre versões da biblioteca.

Os testes estatísticos não se alteraram. Os p-valores de Wilcoxon por *split* e os p-valores combinados pelo método de Fisher coincidem com os das Tabelas 8 e 15.

O teste de Wilcoxon depende da ordenação das diferenças entre cenários e não dos seus valores absolutos, pelo que diferenças desta magnitude não alteram os postos nem o resultado dos testes.

C.5.2 Sensibilidade ao `changepoint_prior_scale`

Nas execuções finais, o `changepoint_prior_scale` do Prophet permaneceu no valor por defeito, conforme indicado no Apêndice B. Para analisar o efeito dessa escolha, os cenários apenas reais e os cenários com complemento sintético foram repetidos com o valor 0,5, no *split* 500.

Nos cenários com complemento, o NRMSE médio manteve-se entre 30,1% e 31,1%, contra 29,1% e 29,5% no valor por defeito. Nos cenários treinados apenas com histórico real reduzido, o erro variou de forma acentuada e sem dire-

ção comum: passou de 208,1% para 562,5% no nível de 5% e de 235,5% para 531,1% no de 10%, mas desceu de 128,8% para 84,1% no de 20%. A ordenação entre os dois grupos manteve-se nos três níveis.

O cenário de controlo com ruído branco não foi repetido, pelo que a comparação entre o complemento sintético e o ruído não foi feita com este valor do parâmetro.

C.5.3 Sensibilidade ao coeficiente de persistência

O coeficiente de persistência da componente residual foi fixado em 0,85 no desenho do gerador, sem estimação por edifício, conforme a Secção 3.6.5. Para testar se as conclusões dependem desse valor, o *pipeline* foi repetido nos cinco *splits* com os coeficientes 0,70 e 0,95.

O ruído de inovação é dimensionado como $\sigma_{\eta} = \sigma_{\text{res}} \sqrt{1 - \varphi^2}$, pelo que a variância do resíduo estabilizado não depende de φ . A repetição altera, assim, a persistência das séries geradas e mantém a sua dispersão. A comparação com o ruído branco não permite a mesma separação, porque a amplitude do ruído não foi igualada à do complemento sintético, conforme a Secção 3.15.

Tabela 17: NRMSE médio dos cenários com complemento sintético por coeficiente de persistência

Histórico real	$\varphi = 0,70$	$\varphi = 0,85$	$\varphi = 0,95$	Com ruído
5%	33,618	34,965	39,405	35,916
10%	33,837	35,292	39,921	35,373
20%	33,054	34,573	39,419	34,219

Nota: cada valor é a média, entre os cinco *splits*, do NRMSE médio por edifício. A coluna $\varphi = 0,85$ usa o coeficiente das execuções finais e a coluna «Com ruído» o cenário de controlo; por resultarem de uma reexecução independente do *pipeline*, os valores diferem em menos de 0,13 pontos percentuais dos da Tabela 6. Os cenários sem complemento sintético não dependem de φ e os respetivos valores coincidem nas três repetições.

A Tabela 17 apresenta o NRMSE médio por coeficiente. O NRMSE cresce com a persistência nos três níveis de histórico e, com $\varphi = 0,95$, o complemento sintético fica acima do cenário de controlo. Com o coeficiente das execuções finais, a diferença entre o complemento sintético e o ruído não excede um ponto percentual em nenhum dos três níveis, e no nível de 20% o sintético fica também acima do controlo.

Os testes estatísticos foram repetidos com $\varphi = 0,70$, o coeficiente que produz o menor erro. A comparação entre o cenário de controlo e o complemento sintético permanece sem significância estatística nos três níveis, com p-valores combinados de 0,386, 0,263 e 0,503. A comparação entre o treino apenas real e o complemento sintético mantém-se significativa, com 0,012, 0,002 e 0,007.

Em nenhum dos três coeficientes o complemento sintético apresentou vantagem estatisticamente significativa sobre o preenchimento da mesma janela com ruído branco. O coeficiente usado nas execuções finais não minimiza o NRMSE médio, que é menor com $\varphi = 0,70$; a escolha foi fixada no desenho e não ajustada aos resultados obtidos.